ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
Московский институт электроники и математики

Суховерхова Диана Дмитриевна

Методы глубокого обучения для исследования критических явлений

Выпускная квалификационная работа
студента образовательной программы бакалавриата
«Прикладная математика»
по направлению подготовки 01.03.04 Прикладная математика

Студент
Д. Д. Суховерхова

Руководитель ВКР
доцент ДПМ МИЭМ НИУ ВШЭ, PhD
Е. А. Буровский

Москва 2022г.

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
Московский институт электроники и математики

ЗАДАНИЕ
на выпускную квалификационную работу

студенту Суховерховой Диане Дмитриевне
Образовательной программы «Прикладная математика»

1. Тема работы
Методы глубокого обучения для исследования критических явлений

2. Цель работы
Исследование применимости методов машинного обучения для изучения модели Изинга с фрустрирующими взаимодействиями

3. Содержание работы
3.1 Сгенерировать данные - конфигурации модели Изинга с фрустрирующими взаимодействиями

3.2 Обучить нейронную сеть на полученных данных

3.3 Проанализировать и обосновать полученные результаты

Проект ВКР представлен студентом «14» февраля 2022г.
Руководитель ВКР _____ Е.А. Буровский

Первый вариант ВКР представлен студентом «21» апреля 2022г.
Руководитель ВКР _____ Е.А. Буровский

Итоговый вариант ВКР представлен студентом «15» мая 2022г.

Руководитель ВКР _____ Е.А. Буровский

Задание выдано студенту «19» декабря 2021г. _____ Е.А. Буровский

Задание принято к исполнению студентом «19» декабря 2021г. _____ Д. Д. Суховерхова

Аннотация

В данной работе проводится исследование модели Изинга с фрустрирующими взаимодействиями методами машинного обучения. Анализируется способность нейронных сетей извлекать информацию о температуре фазовых переходов модели Изинга на квадратной решетке и переносить полученные знания на конфигурации с фрустрирующими взаимодействиями. На основании полученных результатов делается вывод об обобщающей способности нейронных сетей и корректности полученных предсказаний.

Abstract

In this paper, we study the Ising model with frustrating interactions using machine learning methods. We analyze the ability of neural networks to extract information about the temperature of phase transitions of the Ising model on a square lattice and transfer the obtained knowledge to configurations with frustrating interactions. Based on the results, we make a conclusion about the generalizing ability of neural networks and the correctness of the obtained predictions.

Содержание

Введение **5**

1 Модель Изинга **7**

2 Данные **11**

2.1 Генерация данных 11

2.2 Кумулянт Биндера 12

3 Архитектура и обучение нейронной сети **14**

3.1 Архитектура сети 14

3.2 Обучение и предсказания нейронной сети 16

4 Результаты **18**

4.1 Анализ предсказаний для 20 температур 18

4.2 Анализ предсказаний для 100 температур 20

4.3 Зависимость от числа эпох обучения 22

4.4 Анализ результатов на широком диапазоне температур 23

4.5 Закон убывания усредненной функции потерь 24

4.6 Поиск критического поведения по предсказаниям нейронной сети . . 26

5 Заключение **28**

Список использованных источников **30**

Приложения **31**

Введение

Статистическая физика занимается описанием поведения систем с большим числом частиц и исследованием их критического поведения, которое появляется при переходе системы из одного состояния в другое, другими словами - при фазовом переходе. Изучение критического поведения включает в себя рассмотрение нетипичных эффектов, появляющихся на границе фазового перехода, зависимости свойств системы от изменения масштаба и поведения других характеристик. В частности, интерес представляет фазовый переход второго рода некоторых ферромагнитных веществ из ферромагнитного состояния (при котором возникает спонтанная намагниченность при условии отсутствия внешнего магнитного поля) в парамагнитное (без внешнего магнитного поля вещество не имеет магнитных свойств).

Для изучение моделей статистической физики в большинстве случаев применяются методы компьютерного моделирования. Однако, анализ систем с большим количеством частиц в большинстве случаев является вычислительно сложной задачей. В случае, когда требуется проанализировать большой объемом известных данных, можно применять методы машинного обучения, в частности, нейронные сети, которые стали повсеместно использоваться в последнее время. Методы глубокого обучения позволяют выявлять скрытые закономерности, свойственные данным, и применять знания, полученные в процессе обучения, к новым данным.

Однако зачастую параметры нейронной сети, оптимизируемые во время обучения, невозможно интерпретировать, и как следствие - нельзя говорить о том, на каком основании сеть делает предсказания. Вполне возможны случаи, когда сеть просто запоминает обучающую выборку, или же правильные предсказания являются случайным совпадением. Для того, чтобы попытаться ответить на вопрос, понимает ли нейронная сеть физический смысл данных, можно рассмотреть модель с известным точным решением, и сравнить результаты, полученные от нейронной сети, с теоретическими.

Одним из первых исследований по использованию машинного обучения в данной области стала работа [1]. Авторы обучили нейронную сеть предсказывать состояния конфигураций модели Изинга, и на основе полученных предсказаний изучили способность сети определять температуру фазового перехода.

Модель Изинга [2] описывает намагниченность вещества. В классической модели Изинга вещество рассматривается в виде квадратной решетки, в узлах которой расположены частицы самого вещества. Каждой частице сопоставляется число -

"спин" , принимающее значение ± 1. В зависимости от температуры наиболее вероятные конфигурации модели различаются, и возникают два состояния системы: упорядоченное, при котором большинство спинов принимают одинаковое значение, и неупорядоченное. В первом состоянии вещество имеет ферромагнитные свойства, во втором приходит в состояние парамагнетика. Переход из упорядоченного в неупорядоченное состояние происходит при некоторой температуре, которая называется критической.

В данной работе рассматривается модель Изинга с фрустрирующими взаимодействиями. Это модификация классической модели Изинга: спины взаимодействуют не только со своими ближайшими соседями, но и с некоторыми спинами по диагонали таким образом, что решетка из квадратной становится треугольной. В такой модели критическая температура (температура фазового перехода) меняется в зависимости от силы и характера взаимодействия спинов - коэффициента фрустрации.

Исследование модели Изинга с фрустрирующими взаимодействиями с помощью нейронных сетей проводились ранее [3] - авторы обучали нейронную сеть на решение задачи регрессии, то есть предсказание значения критической температуры для различных конфигураций. В данной работе ставится другая задача - решение задачи классификации: нейронная сеть будет предсказывать, в какой из двух фаз (упорядоченная или неупорядоченная) находятся конфигурации модели. Предполагается, что нейронная сеть выучит физические особенности, свойственные классической модели Изинга при температурах ниже и выше критической, и полученные знания сможет перенести на конфигурации с фрустрирующими взаимодействиями.

Результатами работы будут являться анализ предсказаний сети для модели Изинга с различными значениями коэффициента фрустрации, а так же исследование поведения ошибки сети и качества предсказаний вблизи критической температуры.

1 Модель Изинга

Модель Изинга описывает ферромагнитное взаимодействие спинов вещества на решетке и фазовый переход вещества между ферромагнитным и парамагнитным состоянием. Впервые она была описана аналитически в одномерном случае с периодическими граничными условиями Изингом [2]. В двумерном случае аналитическое решение было получено Онзагером [4]. В данной работе рассматривается случай квадратной решетки размера $L \times L$ с периодическими граничными условиями без внешнего магнитного поля.

Гамильтониан классической модели Изинга на квадратной решетке (рис. 1) в условиях отсутствия внешнего магнитного поля задается следующим образом [5]:

$$\mathcal{H} = -J \sum_{x,y=1}^{L} \sigma_{x,y}(\sigma_{x+1,y} + \sigma_{x,y+1}) \tag{1.1}$$

Каждый спин конфигурации $\sigma_{x,y}$, $x,y = 1, \ldots, L$ принимает значение $+1$ или -1, и ближайшие спины взаимодействуют между собой с коэффициентом J. Значение $J > 0$ обозначает ферромагнитное взаимодействие между спинами, то есть при положительном J спины в системе принимают одинаковые значения. В таком случае система приходит в упорядоченное состояние, и возникает спонтанная намагниченность при условии отсутствия внешнего магнитного поля. Коэффициент $J < 0$ означает антиферромагнитное взаимодействие, в котором спины попарно принимают противоположные значения.

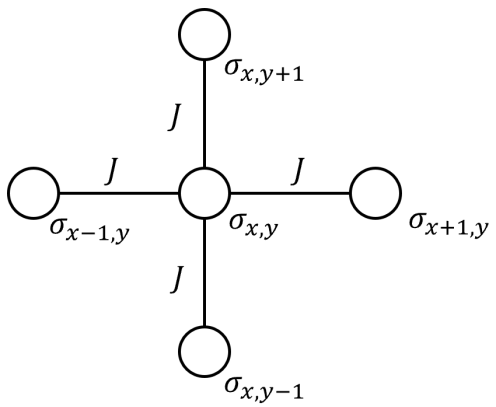

Рис. 1: Узел решетки $\sigma_{x,y}$ в классической модели Изинга.

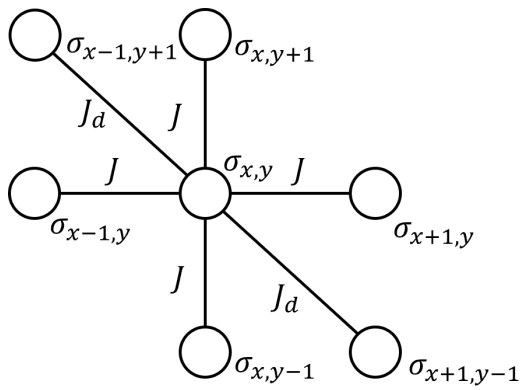

Рис. 2: Узел решетки $\sigma_{x,y}$ в модели Изинга с фрустрирующими взаимодействиями.

С добавлением взаимодействия между диагональными соседями получим треугольную решетку (рис. 2)

За диагональное взаимодействие спинов отвечает коэффициент J_d. В данной работе рассматриваются (без ограничения общности) значения $J = 1$, $J_d \in [-1, 0]$. Такую модель будем называть моделью Изинга с геометрическими фрустрирующими взаимодействиями. При $J_d = 0$ получим описанную выше модель Изинга с квадратной решеткой.

В условиях отсутствия внешнего магнитного поля энергия конфигурации с фрустрирующими взаимодействиями задается гамильтонианом [6], [7]:

$$\mathcal{H} = -\sum_{x,y=1}^{L} \left[J\sigma_{x,y}(\sigma_{x+1,y} + \sigma_{x,y+1}) + J_d\sigma_{x+1,y+1} \right] \tag{1.2}$$

Для минимизации энергии $E = \mathcal{H}$ (1.2) каждый спин должен принимать значение, равное его ближайшим соседям с ферромагнитным взаимодействием, и при этом - обратное спинам с антиферромагнитным взаимодействием. Поэтому спин $\sigma_{x,y}$ получается фрустрированным, то есть его состояние зависит от значений коэффициентов взаимодействия.

Для исследования равновесных свойств модели Изинга рассмотрим ее статистическую сумму [5]:

$$Z(\beta) = \sum_{\langle\sigma\rangle} \exp\left(-\beta\mathcal{H}\right),$$

где $\beta = \dfrac{1}{k_B T}$, k_B - постоянная Больцмана, суммирование происходит по всем возможным состояниям системы $\langle\sigma\rangle$.

Вероятность получения конфигурации системы при заданной температуре задается распределением Гиббса:

$$P(\sigma_i) = \frac{\exp\left(-\beta\mathcal{H}_i\right)}{Z}, \tag{1.3}$$

где $\mathcal{H}_i$ - значение гамильтониана при конфигурации спинов σ_i.

Для модели Изинга можно оценить некоторые физические характеристики, в частности, энергию и моменты намагниченности. В общем случае математическое ожидание некоторой величины $\mathcal{O}$ находится по формуле [5]:

$$\langle\mathcal{O}\rangle = \sum_{\langle\sigma\rangle} \mathcal{O}\frac{\exp\left(-\beta\mathcal{H}\right)}{Z}$$

Таким образом, можно определить среднюю энергию и намагниченность модели Изинга при заданном размере решетки и температуре:

$$\langle E \rangle = \sum_{\sigma_i} E_i \frac{\exp\left(-\beta \mathcal{H}_i\right)}{Z},$$

где E_i - энергия системы в состоянии σ_i.

Намагниченность системы считается как сумма всех значений спинов:

$$M = \sum_{x,y=1}^{L} \sigma_{x,y}$$

Средняя намагниченность:

$$\langle M \rangle = \sum_{\sigma_i} M_i \frac{\exp\left(-\beta \mathcal{H}_i\right)}{Z},$$

где M_i - намагниченность системы в состоянии σ_i.

Для модели Изинга с фрустрирующими взаимодействиями возможно точное нахождение температуры фазового перехода при заданных коэффициентах взаимодействия J и J_d. Температура фазового перехода T_c находится из следующего уравнения [6]:

$$\left(\sinh \frac{2J}{k_B T_c}\right)^2 + 2 \sinh \frac{2J}{k_B T_c} \sinh \frac{2J_d}{k_B T_c} = 1 \tag{1.4}$$

$\frac{J_d}{J}$	0.0	-0.1	-0.2	-0.3	-0.4	-0.5	-0.6	-0.7	-0.8	-0.9	-1.0
$\frac{T_c}{J}$	2.269	2.105	1.932	1.749	1.554	1.342	1.110	0.854	0.576	0.288	0.032

Таблица 1: Численные решения уравнения (1.4), $J = 1$ (с округлением до 3-х знаков после запятой)

В таблице 1 представлены значения критической температуры для нескольких значений $J_d \in [-1,\, 0]$, $J = 1$. Можно заметить, что при увеличении модуля $|J_d|$, значение критической температуры убывает практически до нуля. В дальнейшем численные решения данного уравнения будут использованы при анализе правильности предсказания фазы, в которых находятся конфигурации спинов, нейронной сетью.

Фазовый переход в модели Изинга также обусловлен изменением корреляционной длины ξ, которая задает размер флуктуаций в системе при заданной температуре,

то есть областей, в которых намагниченность отличается от средней. При стремлении температуры к критической (слева и справа) корреляционная длина стремится к бесконечности ($\xi \xrightarrow[|T-T_c|\to 0]{} \infty$) и рост задается степенным законом [5]:

$$\xi \sim |T - T_c|^{-\nu}$$

ν является критическим показателем модели Изинга; для двумерной модели $\nu = 1$.

Наша гипотеза состоит в том, что на основе предсказаний, полученных после обучения нейронной сети, можно отследить данный степенной рост корреляционной длины. Это будет означать, что нейронная сеть "видит" критическое поведение вблизи температуры фазового перехода и извлекает знания о физических законах модели Изинга из обучающих данных. Также мы предполагаем, что по критерию роста корреляционной длины можно делать выводы об обобщающей способности нейронной сети и о том, как нейронная сеть определяет критическую температуру в случае модели с фрустрирующими взаимодействиями.

2 Данные

2.1 Генерация данных

Обучающий и тестовый датасеты для нейронной сети состоят из черно-белых "изображений" - матриц размера $L \times L$, каждый элемент которой имеет значение $+1$ или -1. Для генерации данных используется алгоритм Метрополиса [5]:

1. Матрица, представляющая собой решетку спинов, случайным образом заполняется значениями ± 1;

2. На решетке случайно выбирается один спин $\sigma_{x,y}$;

3. Вычисляется вероятность перехода системы из конфигурации σ_i в $\sigma_i^{'}$, в которой значение $\sigma_{x,y}$ меняется на противоположное ($\sigma_i^{'} = \{\sigma_i | \sigma_{x,y} \equiv -\sigma_{x,y}\}$):

$$P(\sigma_i \to \sigma_i^{'}) = \begin{cases} 1, \, \Delta E < 0 \\ \exp\left(-\beta \Delta E\right), \, \Delta E > 0 \end{cases}$$

   (ΔE - разность энергий системы при конфигурациях σ_i и $\sigma_i^{'}$)

4. Из равномерного распределения генерируется случайное число p; если $p < P(\sigma_i \to \sigma_i^{'})$, то изменение спина $\sigma_{x,y}$ "принимается" и его значение изменяется на противоположное;

5. Шаги 2-4 повторяются L^2 раз за каждый шаг Монте-Карло (всего $nsweeps$ шагов, параметр задается отдельно).

Поскольку генерация данных начинается со случайного состояния, необходимо пропустить несколько начальных шагов Монте-Карло, чтобы система пришла в состояние равновесия. Время, необходимое для достижения равновесия, называется временем термализации, и, согласно [8], составляет $20 \times L^{2.15}$. После процесса термализации, каждое изображение сохраняется раз в $2 \times L^{2.15}$ $mcsweep$ [9].

Таким образом конфигурации модели Изинга генерируются из распределения Гиббса (1.3) для каждой комбинации J_d и L. Рассматриваемые размеры решеток: $L = 10, 20, 30, 40, 60, 80$; значения $J_d = 0.0, -0.3, -0.5, -0.7, -0.9$.

Каждое изображение генерируется для своего значения температуры. Для тренировочного датасета для каждой температуры генерируется 2048 примеров. Для

тестового датасета для каждого из значений температуры генерируется 512 изображений.

Также для каждого изображения сохраняются метки класса, полученные на основе значений критической температуры из уравнения (1.4):

- 0 - если температура конфигурации ниже критической
- 1 - если температура конфигурации выше критической

2.2 Кумулянт Биндера

Также для оценки критической температуры и критического показателя ν используется кумулянт Биндера [5], [7]:

$$U(T_c) = 1 - \frac{\langle M^4 \rangle}{3\langle M^2 \rangle^2} \tag{2.1}$$

Поскольку мы рассматриваем модель Изинга с конечным размером решетки, нужно учитывать поправки на $L < \infty$. В таком случае корреляционная длина $\xi \sim L$. Значения кумулянта при заданных значениях параметров J и J_d зависят только от размера решетки L, и графики имеют одну точку пересечения в значении критической температуры T_c. Если данные генерируются верно, то при температуре ниже критической $\langle M^4 \rangle = \langle M^2 \rangle = 1$, и $U(T_c) = \frac{2}{3}$. При увеличении температуры величины $\langle M^4 \rangle$ и $\langle M^2 \rangle$ должны иметь распределение Гаусса, и можно показать, что $\langle M^4 \rangle = 3\langle M^2 \rangle$. В таком случае значение кумулянта Биндера должно стремиться к нулю.

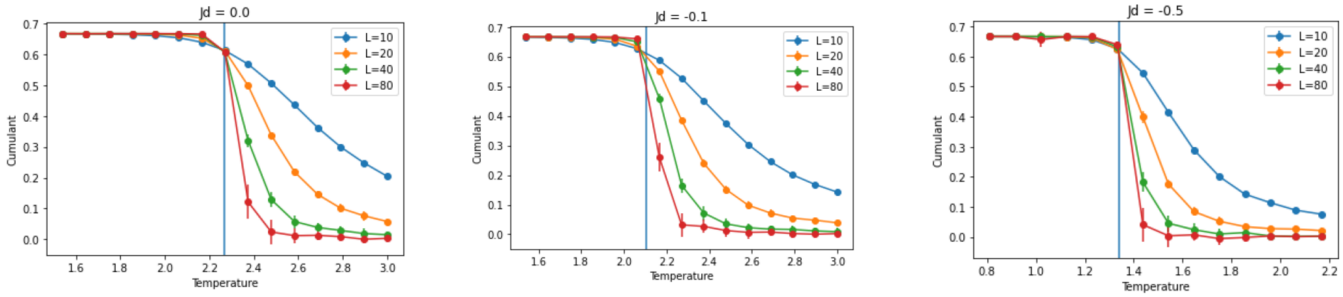

(a) (b) (c)

Рис. 3: Кумулянты Биндера (2.1), при (a) $J_d = 0.0$ в диапазоне $T \in [1.5, 3.0]$, (b) $J_d = -0.1$ в диапазоне $T \in [1.5, 3.0]$, (c) $J_d = -0.5$ в диапазоне $T \in [0.5, 2.2]$. Вертикальной линией обозначается теоретическая температура фазового перехода, уравнение (1.4).

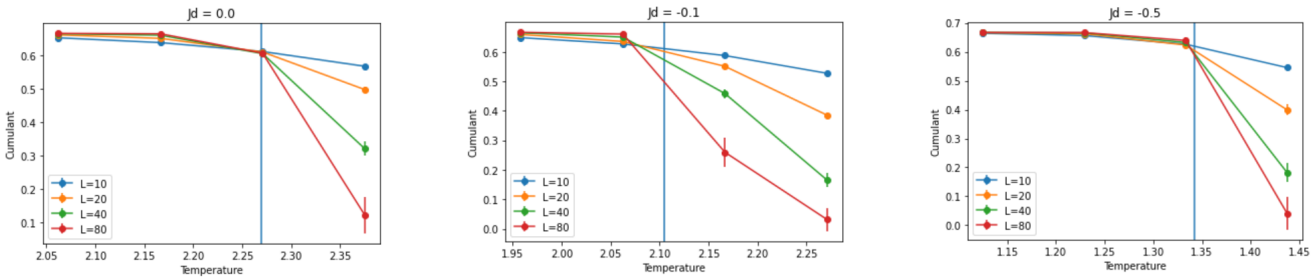

(a) (b) (c)

Рис. 4: Кумулянты Биндера (2.1), при (a) $J_d = 0.0$, (b) $J_d = -0.1$, (c) $J_d = -0.5$ вблизи критических температур. Вертикальной линией обозначается теоретическая температура фазового перехода , уравнение (1.4).

На рис. 3 и рис. 4 представлены графики кумулянтов при различных значениях параметра J_d, вычисленных при генерации данных при 2000000 шагов Монте-Карло в диапазонах $[1.5, 3.0]$ для $J_d = 0.0, -0.1$ и $[0.5, 2.2]$ для $J_d = -0.5$, всего 15 значений. Такие границы выбраны исходя из близости к значениям критических температур, полученных из уравнения (1.4).

Критические температуры для каждого из рассмотренных значений параметра J_d получены численно из уравнения (1.4) и представлены в таблице 2.

J_d	T_c, теор.	Точка пересечения графиков $U(T_c)$
0.0	2.269	2.253 ± 0.01
-0.1	2.105	2.075 ± 0.005
-0.5	1.342	1.331 ± 0.01

Таблица 2: Значения критической температуры, полученные из анализа кумулянтов Биндера.

Из полученных графиков и их точек пересечения можно сделать вывод, что экспериментальная температура фазового перехода получается близкой к теоретической, с известными погрешностями. Также видно, что при температурах ниже критической значения кумулянтов примерно равны $\frac{2}{3}$, а при температурах выше критической значения кумулянтов постепенно снижаются до нуля, что совпадает с предположением о нормальном распределении $\langle M^2 \rangle$ и $\langle M^4 \rangle$.

3 Архитектура и обучение нейронной сети

3.1 Архитектура сети

В реализации архитектуры нейронной сети, а также обучении и тестировании использовалась библиотека pytorch.

Нейронная сеть состоит из следующих слоев:

1. Сверточный слой Conv2d с 1 входным каналом и 64 выходными, размер свертки 2×2, шаг (stride) свертки $= 1$,
2. Слой MaxPool2d 2×2,
3. Слой активации ReLU,
4. Полносвязный (linear) слой с $64 \times (L/2 - 1) \times (L/2 - 1)$ нейронами на входе и 64 на выходе,
5. Слой активации ReLU,
6. Полносвязный (linear) слой с 64 входными нейронами.

Layer (type:depth-idx)	Output Shape	Param #
Conv2d: 1-1	[-1, 64, 19, 19]	320
MaxPool2d: 1-2	[-1, 64, 9, 9]	–
ReLU: 1-3	[-1, 64, 9, 9]	–
Linear: 1-4	[-1, 64]	331,840
ReLU: 1-5	[-1, 64]	–
Linear: 1-6	[-1, 1]	65
Total params: 332,225 Trainable params: 332,225 Non-trainable params: 0		

Таблица 3: Пример количества параметров нейронной сети для $L = 20$

Поскольку параметры нейронной сети зависят от размера решетки, для каждого значения L создается отдельная модель, которая обучается на изображениях одинакового размера. В машинном обучении существует способ приведения всех

изображений к одной размерности - например, можно было бы дополнить матрицы конфигураций нулями по краям до максимального из рассматриваемых размера решетки, но такой способ является неэффективным, так как тогда нейронная сеть будет хорошо классифицировать конфигурации большого размера и показывать низкое качество предсказаний для небольших размеров решетки.

Сверточный слой нейронной сети с 1 входным каналом задается формулой [10]:

$$S(x,y,t) = \sum_{m=0}^{d-1} \sum_{n=0}^{d-1} I(x+m,y+n)K(m,n,t),$$

где x, y - пиксель входного изображения,
t - номер выходного канала,
d - размер свертки,
I - входное изображение,
K - свертка, значения которой оптимизируются в ходе обучения.

Сверточный слой в данной архитектуре используется неслучайно: обычно сверточные слои используются для нахождения особенностей во входных изображениях вне зависимости от их расположения. В нашем случае - это набор спинов вблизи точки фазового перехода и увеличение корреляционной длины, которое нейронная сеть сможет увидеть в новых, неизвестных во время обучения данных.

Слой MaxPooling уменьшает размер изображения путем выбора максимального из элементов в области фильтра.

Слой активации ReLU:

$$ReLU(\overline{x}) = \max(0, \overline{x}),$$

где $\overline{x} = (x, y)$ - пиксель входного изображения.

Полносвязный слой задается формулой:

$$z = Wx + b,$$

где W - матрица весов полносвязного слоя, значения которой оптимизируются в процессе обучения,
x - входные данные,
b - смещение - параметр, который также оптимизируется во время обучения.

Последний полносвязный слой имеет на выходе 1 нейрон - результатом пред-

сказания является вероятность принадлежности классу 1, то есть является ли температура, при которой было сгенерировано входное изображение, выше критической.

К полученным на последнем полносвязном слое данным применяется активация Sigmoid:

$$\sigma(x) = \frac{1}{1 + \exp -x}$$

Полученные предсказания вероятности класса 1 после такого слоя активации будут находится в интервале $[0,\ 1]$. В реализации используется функция BCEWithLogitsLoss: данная функция включает в себя слой активации Sigmoid и является более численно устойчивой [11].

3.2 Обучение и предсказания нейронной сети

Перед обучением, тренировочные данные перемешиваются и разделяются на "пакеты" (батчи) - по 4 изображения на каждую итерацию обучения нейронной сети. Разделение на батчи ускоряет процесс обучения и препятствует переобучению сети, поскольку минимизация функции потерь происходит при большем числе примеров. Тестовые данные, в отличие от тренировочных, не перемешиваются, так как результаты тестирования не зависят от порядка получения тестовых данных, и данные передаются по одной конфигурации.

В качестве функции потерь выбрана бинарная кросс-энтропия:

$$Q(y_i, \hat{y}_i) = -\frac{1}{n} \sum_{i=1}^{n} \left[y_i \cdot \log \hat{y}_i + (1 - y_i) \cdot \log \left(1 - \hat{y}_i\right) \right], \tag{3.1}$$

где y_i - правильный ответ, $\hat{y}_i$ - предсказание сети, n - количество изображений.

Бинарная кросс-энтропия стремится увеличить потери для неточных предсказаний: поскольку предсказания сети $\hat{y}_i$ - непрерывные величины, которые находятся в диапазоне $[0,\ 1]$ (в отличие от y_i, которые принимают значения 0 и 1), то неверное предсказание будет вносить большой вклад в значение функции потерь за счет логарифма $\log(\hat{y}_i)$.

В качестве оптимизации весов выбран алгоритм Adam [12]:

$$m_j^t = \frac{\beta_1 m_j^{t-1} + (1 - \beta_1)(\nabla Q(w^{t-1}))_j}{1 - \beta_1^t}$$

$$v_j^t = \frac{\beta_2 v_j^{t-1} + (1-\beta_2)(\nabla Q(w^{t-1}))_j^2}{1-\beta_2^t}$$

$$w_j^t = w_j^{t-1} - \frac{\eta_t}{\sqrt{v_j^t} + \varepsilon} m_j^t,$$

где $\eta_t = 10^{-4}$ - learning-rate, параметр, контролирующий обновление весов,
β_1, β_2, ε - параметры, которые задаются при инициализации ($\beta_1 = 0.9$, $\beta_2 = 0.999$, $\varepsilon = 10^{-8}$),
t - шаг алгоритма,
w_j^t - оптимизируемый параметр (вес),
$\nabla Q(w^{t-1})$ - градиент функции потерь.

Чтобы проверить, как сеть справляется с пониманием состояний, соответствующих температуре фазового перехода, и переносом физического смысла модели Изинга на новые состояния с фрустрирующими взаимодействиями, обучение происходит только на данных, сгенерированных для нефрустрированного состояния, то есть при $J_d = 0.0$. Таким образом, при оптимизации параметров нейронная сеть "не видит" фрустрированные состояния; в тестовой выборке же находятся изображения, соответствующие, в том числе, ненулевым значениям параметра J_d.

Ожидается, что нейронная сеть будет с высокой точностью определять классы состояний, сгенерированных при температурах, далеких от критической: при низких температурах предсказания сети должны принимать значение 0, а при высоких = 1. В области же критической температуры происходит переход между двумя состояниями, который характеризуется ростом корреляционной длины до бесконечности (в случае конечного размера решеток - до L). В этой области конфигурации выше и ниже критической температуры "похожи" то есть сеть должна быть неуверена в ответе, и ожидаемый выход сети для таких конфигураций = 0.5.

4 Результаты

4.1 Анализ предсказаний для 20 температур

На рис. 5 представлены результаты тестирования сети, обученной на конфигурациях в диапазоне $T_c \pm 0.3$, $T_c = 2.269$. Для начальной проверки выдвинутых ранее прелположений о результатах работы нейронной сети была сгенерирована небольшая выборка, включающая 20 значений температур. Сеть обучалась одну эпоху.

В качестве определения критической температуры были также рассмотрены усредненные значения функции потерь (3.1):

$$\overline{Q_j} = \frac{1}{N} \sum_{i=1}^{N} Q(y_i^j, \hat{y}_i{}^j), \tag{4.1}$$

где $N = 512$, $j = 1, \ldots, K$ - номер температуры из выбранного диапазона (в данном случае $K = 20$).

Поскольку выбранная функция потерь усиливает потери для ошибочных предсказаний, была выдвинута гипотеза, что в области фазового перехода, где сеть должна быть неуверена в ответе, функция потерь будет принимать максимальные значения.

Изображенные предсказания сети также усреднялись:

$$p_j = \frac{1}{N} \sum_{i=1}^{N} \hat{y}_i{}^j \tag{4.2}$$

Также были исследованы погрешности измерений: так как в датасете на каждое значение температуры приходится по 512 изображений, то можно посчитать стандартное отклонение предсказаний сети для каждой температуры:

$$\sigma_j = \sqrt{\frac{\sum_{i=1}^{n} (\hat{y}_i{}^j - \overline{\hat{y}^j})^2}{n}} \tag{4.3}$$

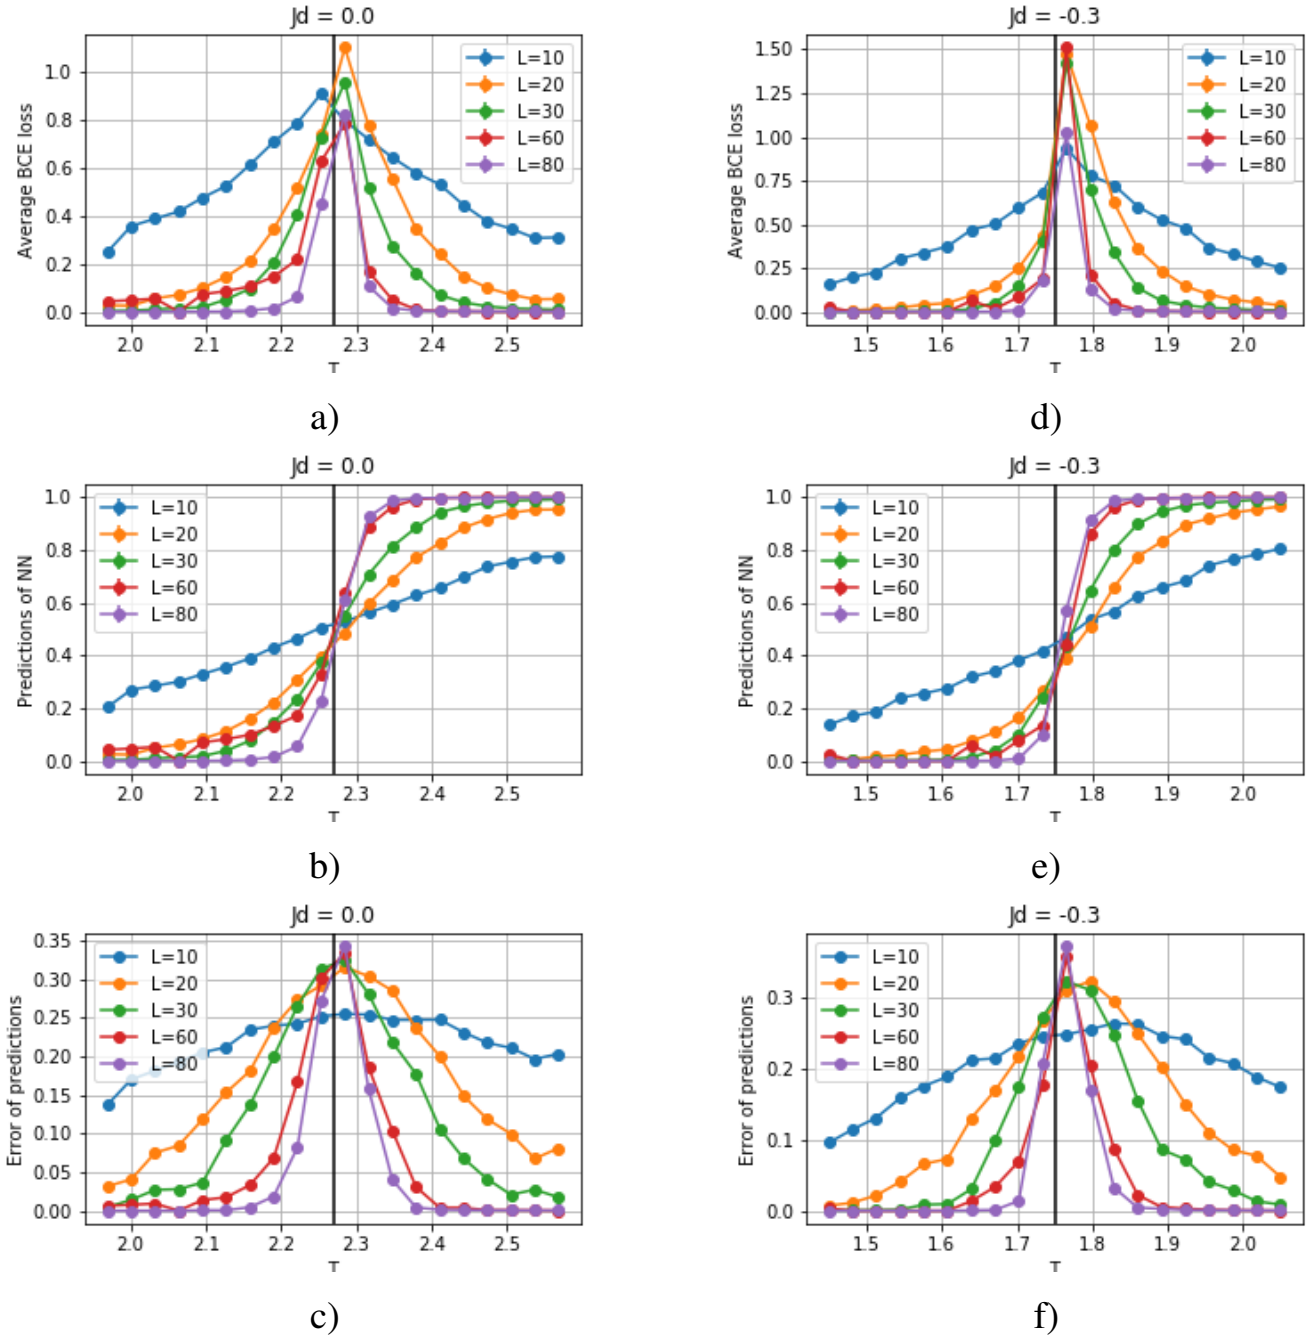

Рис. 5: Усредненные функция потерь (a, d) (формула (4.1)), предсказания (b, e) (формула (4.2)) и погрешности предсказаний (c, f) (формула (4.3)) сети для $J_d = 0.0$ и $J_d = -0.3$ в диапазоне $T_c \pm 0.3$ для 20 значений температур; вертикальной линией обозначена критическая температура, уравнение (1.4).

Для нефрустрированных состояний (рис. 5, (a-c)) можно увидеть, что полученные результаты совпадают с ожидаемыми: вблизи критической температуры сеть действительно чаще и сильнее ошибается (a), предсказания сети приблизительно равны 0.5 (b), и стандартное отклонение предсказаний также достигает пика (c). При этом, при температурах, находящихся на краю рассматриваемого интервала, сеть ошибается редко и верно предсказывает вероятность быть выше критической

температуры.

Также можно заметить, что при размере решетки $L = 10$ результаты заметно ухудшаются: это объясняется малостью размера решетки и тем, что корреляционная длина для таких конфигураций даже на температурах, далеких от T_c, совпадает со всей решеткой.

На графиках рис. 5 (d-f) показаны величины (4.1), (4.2) и (4.3) для $J_d = -0.3$. Поскольку появились фрустрирующие взаимодействия между спинами, критическая температура изменилась. Во время обучения данные о конфигурациях с ненулевыми значениями J_d не использовались - нейронная сеть получала информацию только о модели Изинга на квадратной решетке. Однако, усредненные значения функции потерь и погрешности предсказания так же достигают пика, но уже вблизи новой критической температуры, а предсказания сети в этой области примерно равны 0.5. Можно сделать вывод, что сеть действительно "видит" критическую температуру и в процессе обучения извлекла информацию о конфигурациях при фазовом переходе.

Дополнительные графики для $J_d = -0.5$ -0.7 и -0.9 приведены в приложении 1. Можно увидеть, что при увеличении силы фрустрирующих взаимодействий результаты ухудшаются, и при $J_d = -0.9$ мало похожи на ожидаемые. При этом пики ошибок так же находятся в области критической температуры, и сеть хорошо классифицирует состояния на границах диапазона температур.

4.2 Анализ предсказаний для 100 температур

Чтобы детальнее проанализировать поведение сети вблизи критической температуры, число рассматриваемых значений температур было увеличено до 100. Обучение также происходило на примерах без фрустрирующих взаимодействий в течение одной эпохи. Результаты тестирования представлены на рис. 6 и в приложении 2.

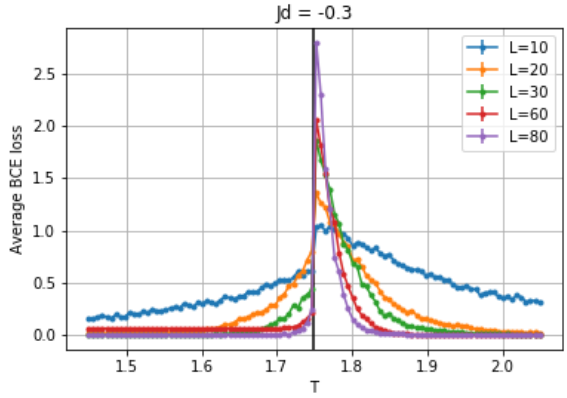

a)

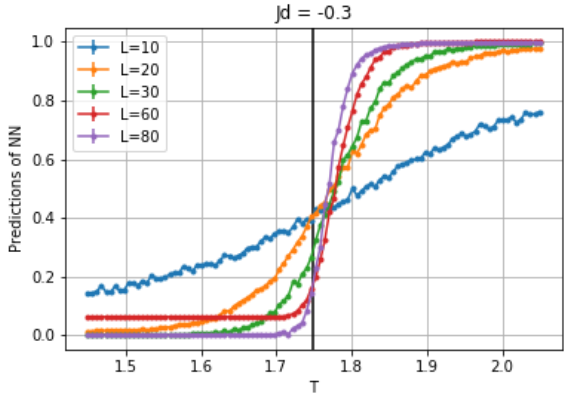

b)

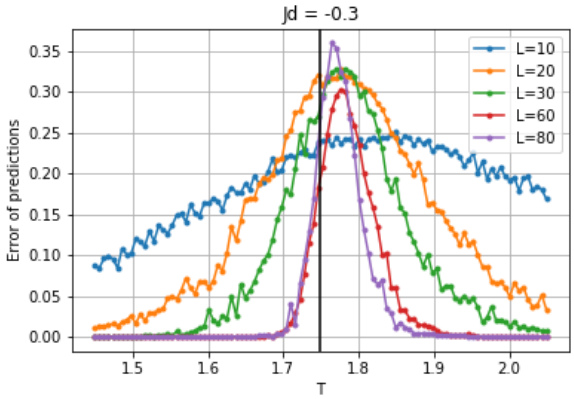

c)

Рис. 6: Усредненные функция потерь (a) (формула (4.1)), предсказания (b) (формула (4.2)) и погрешности предсказаний (c) (формула (4.3)) сети для $J_d = -0.3$ в диапазоне $T_c \pm 0.3$ для 100 значений температуры; вертикальной линией обозначена критическая температура, уравнение (1.4).

Можно увидеть, что основные результаты, полученные в п.4.1, сохраняются: максимальные значения усредненной функции потерь и погрешностей предсказаний также наблюдаются вблизи критической температуры, и график усредненных предсказаний сети аналогичен рис. 5, (e).

Однако, наблюдается следующая тенденция: при увеличении $|J_d|$ функция потерь теряет симметричность - она испытывает скачок после прохождения критической температуры. Также средние значения ответов сети в критической температуре снижаются, и максимумы погрешностей предсказаний смещаются вправо. Можно сказать, что сеть определяет критическую температуру правее ее теоретического значения.

При $J_d = -0.9$ полученные результаты оказываются крайне неточными, и делать какие-либо выводы в этом случае не представляется возможным.

4.3 Зависимость от числа эпох обучения

При анализе результатов на 100 температурах, в частности, при $J_d = -0.7$ (рис. 15), было замечено, что усредненная функция потерь в некоторых случаях после критической температуры снижается не постепенно, как было ранее, а сохраняет свое значение почти неизменным. Была выдвинута гипотеза о том, что это зависит от времени обучения нейронной сети, так как до этого обучение занимало всего одну эпоху. Поэтому были проведены дополнительные эксперименты по увеличению времени обучения нейронной сети.

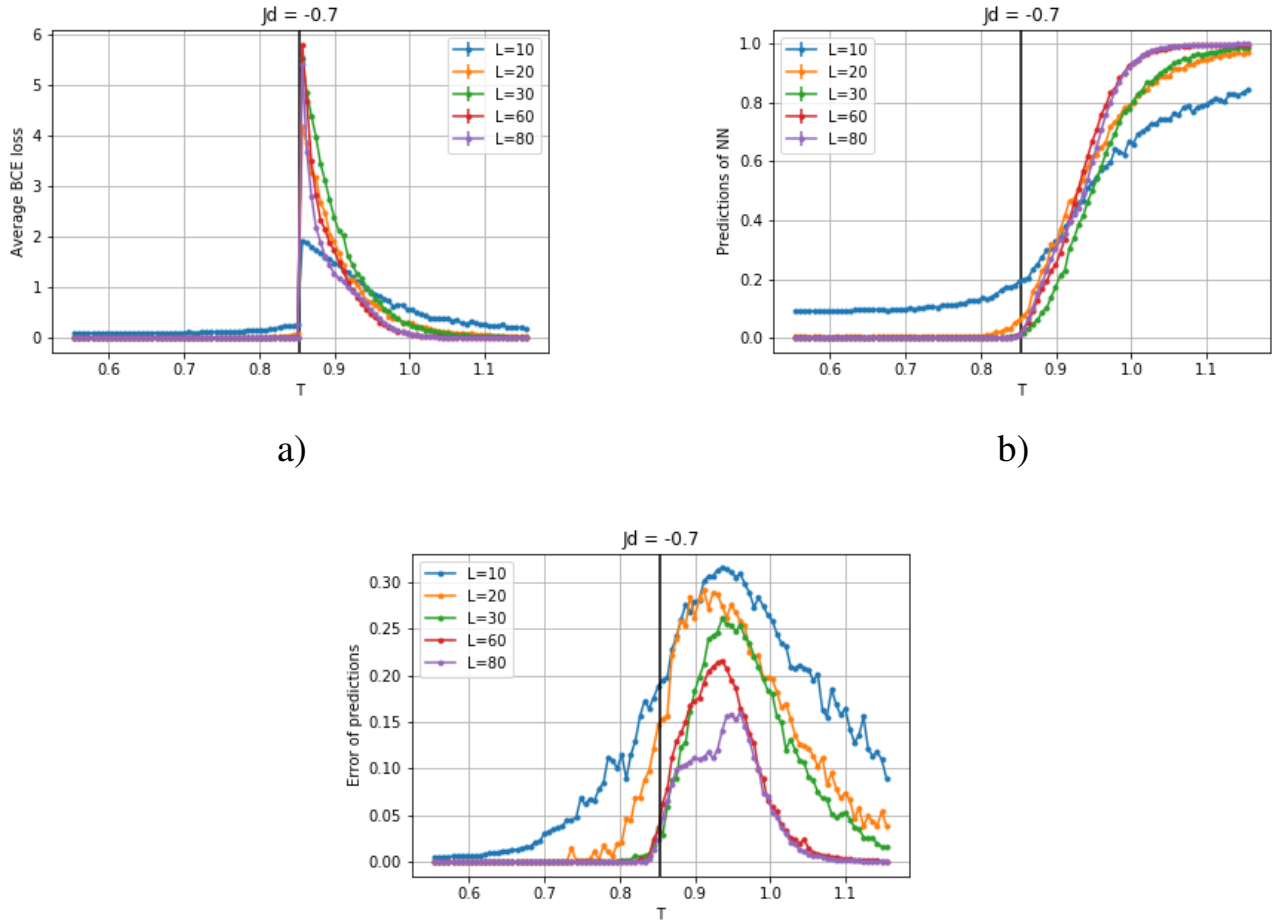

Рис. 7: Усредненные функция потерь (a) (формула 4.1), предсказания (b) (формула 4.2) и погрешности предсказаний (c) (формула 4.3) сети, обученной в течение 2 эпох, для $J_d = -0.7$ в диапазоне $T_c \pm 0.3$ для 100 значений температур; вертикальной линией обозначена критическая температура.

На рис. 7 показаны результаты для сети, обученной в течение 2 эпох. Видно, что результаты незначительно улучшились: визуально критическая температура все еще далека от теоретической, но теперь функция потерь убывает одинаково для всех размеров решетки. Можно сделать вывод, что увеличение числа эпох влияет на

результаты предсказаний нейронной сети.

4.4 Анализ результатов на широком диапазоне температур

Также, аналогично работе [3], были проведены эксперименты по определению критической температуры нейронной сетью, обученной на конфигурациях, чья температура далека от критической. Были рассмотрены 50 значений температуры из интервала $[0.03,\ 3.5]$, которые включают в себя все критические температуры для коэффициентов J_d, рассматриваемых в данной работе (таблица 2).

Целью данных экспериментов было выяснить, улучшатся ли результаты для фрустрированных конфигураций с $J_d = -0.3;\ -0.5;\ -0.7;\ -0.9$, если при обучении сеть будет видеть соответствующие им критические температуры, или же наоборот - результаты станут хуже и величины, описанные в п. 4.1, будут иметь максимумы при других значениях температуры, далеких от критической. Полученные результаты показаны на рис. 8 и в приложении 3.

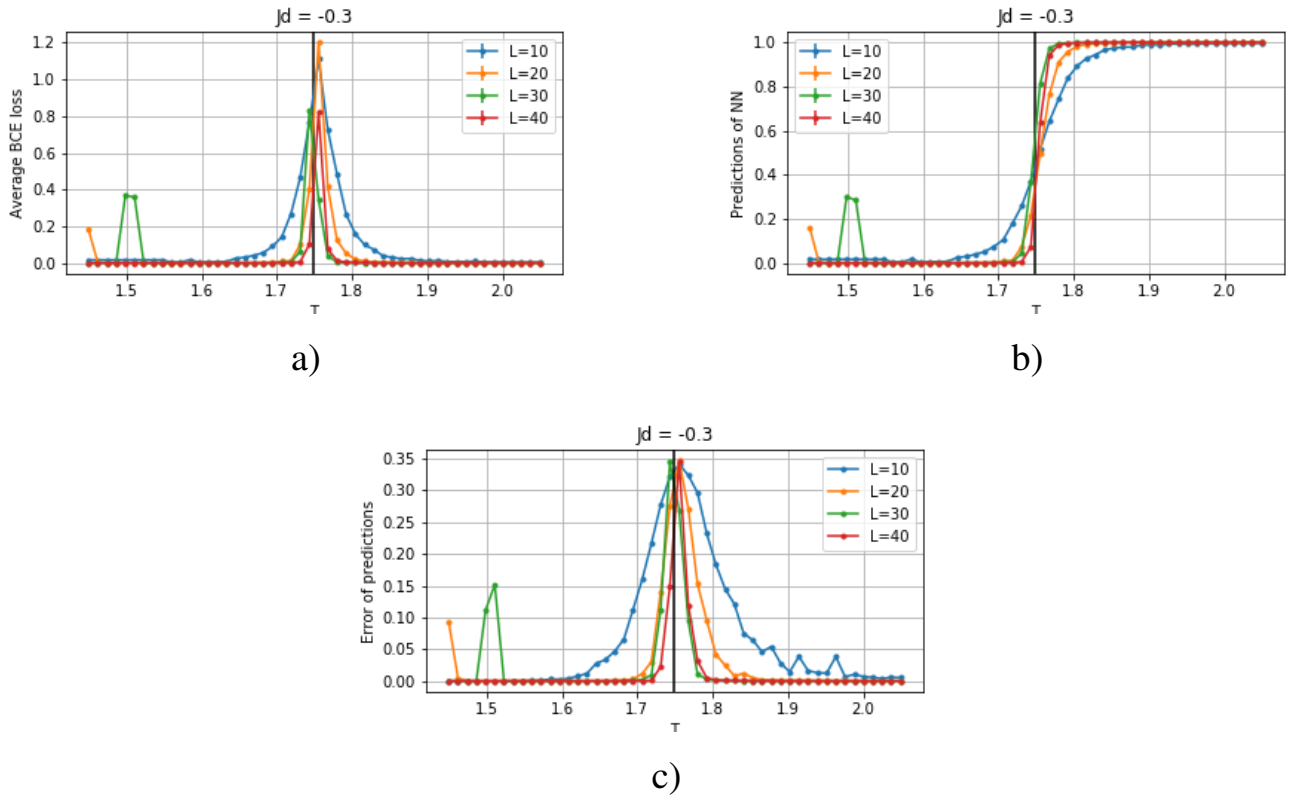

Рис. 8: Усредненные функция потерь (a) (формула (4.1)), предсказания (b) (формула (4.2)) и погрешности предсказаний (c) (формула (4.3)) сети для $J_d = -0.3$ в диапазоне $[0.03,\ 3.5]$ для 50 значений температур; вертикальной линией обозначена критическая температура, уравнение (1.4).

Можно видеть, что результаты не сильно изменились: сеть все еще верно классифицирует ферромагнитное и парамагнитное состояния на далеких от критической

температурах и имеет пики усредненной функции потерь и стандартного отклонения предсказаний вблизи точки фазового перехода. Однако, наблюдаются локальные максимумы при низких температурах. Такой эффект мог появиться из-за недостаточного времени обучения, так как нейронная сеть обучалась одну эпоху.

4.5 Закон убывания усредненной функции потерь

Следующим шагом анализа результатов стало исследование закона, по которому убывает усредненная функция потерь. Мы выясняли, как ведет себя функция потерь - как степенная функция или функция экспоненты.

Чтобы определить степенную зависимость $y \approx ax^{\alpha}$, прологарифмируем обе части данного соотношения: $\log y = \log a + \alpha \log x$. Тогда следует построить графики в двойной логарифмическом масштабе: если степенная зависимость присутствует, данные вытягиваются в прямую линию с коэффициентом наклона α.

Аналогично, для определения экспоненциального закона $y \approx a \exp\left(\frac{x}{\xi}\right)$, графики функции потерь строятся в полулогарифмическом масштабе: из выражения $\log y = \log a + \frac{x}{\xi}$ следует, что при экспоненциальной зависимости убывания функции потерь, данные лягут на одну прямую в полулогарифмическом масштабе.

Цель такого анализа - выявление критического поведения корреляционной длины. Так как вблизи точки фазового перехода $\xi \sim |T - T_c|^{-\nu}$ и на решетках конечного размера $\xi \xrightarrow[|T-T_c|\to 0]{} L$, критическое поведение присутствует, если зависимость - степенная, поэтому будем проверять соотношение $\log(|T - T_c|) \sim \dfrac{1}{\nu} \log(\dfrac{1}{L})$ в дважды логарифмическом масштабе.

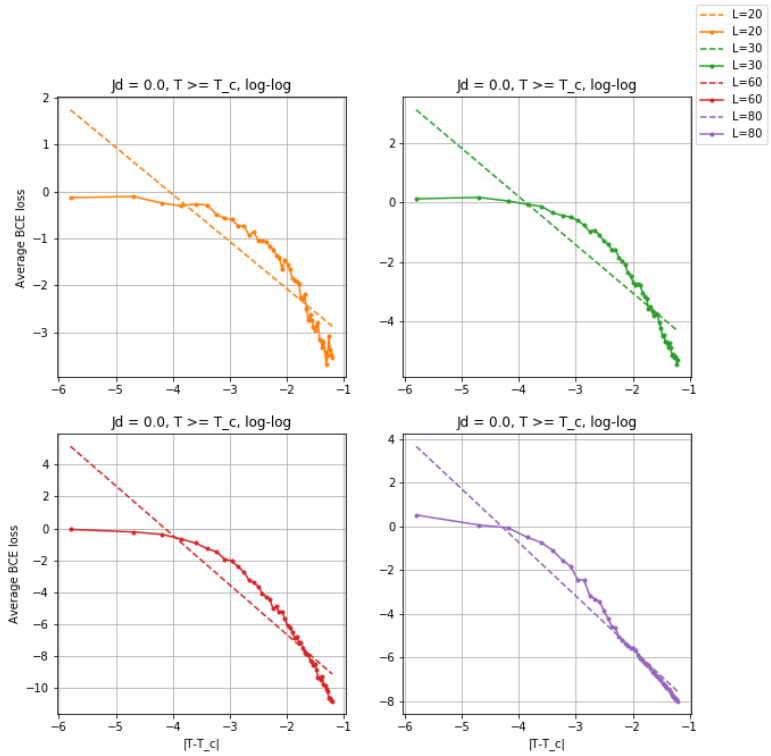

Рис. 9: Усредненная функция потерь (4.1) при температурах выше критической, в двойном логарифмическом масштабе, $J_d = 0.0$.

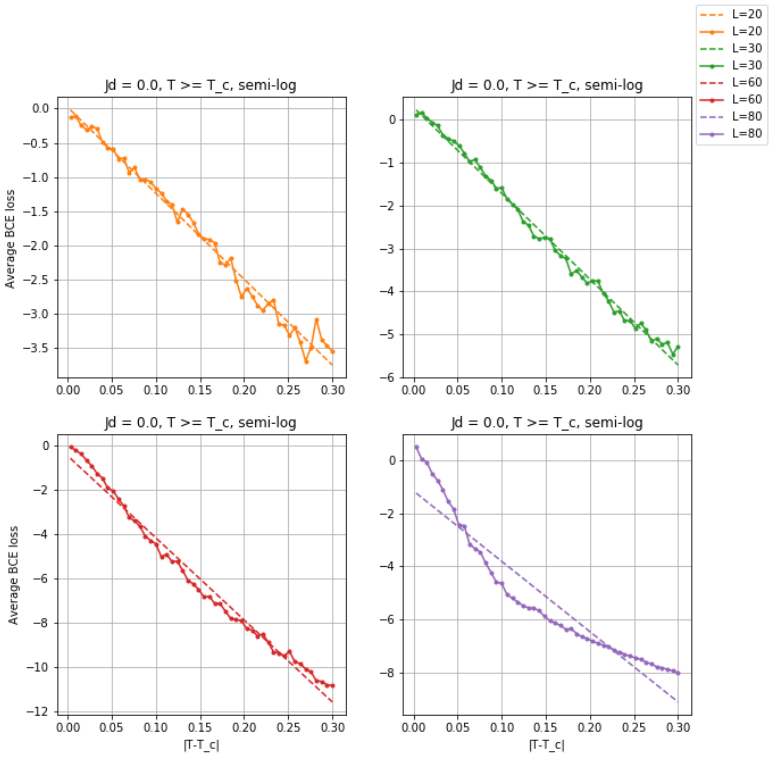

Рис. 10: Усредненная функция потерь (4.1) при температурах выше критической, в полулогарифмическом масштабе, $J_d = 0.0$.

На рис. 9 и рис. 10, а также в приложении 4, показаны полученные результаты. Здесь в качестве x рассматриваются не сами температуры, а значения $|T - T_c|$, всего 100 точек, при $T \geq T_c$. Затем имеющиеся данные аппроксимируются прямыми, которые изображены пунктирными линиями.

Можно сделать вывод, что усредненная функция потерь убывает скорее по экспоненциальному закону, чем по степенному, поскольку данные лучше аппроксимируются прямой на рис. 10. Это означает, что степенного поведения корреляционной длины не наблюдается, и нельзя говорить о критическом поведении, которое обнаруживает нейронная сеть.

4.6 Поиск критического поведения по предсказаниям нейронной сети

Дополнительно, анализ роста корреляционной длины, который обнаруживает нейронная сеть, был проведен по предсказаниям, полученным на интервале $T_c \pm 0.3$ для 100 точек. Для этого мы находили максимальное значение погрешностей предсказаний (4.3) для каждой комбинации L и J_d и исследовали зависимость $|T^{'} - T_c|$, где $T^{'}$ - температура, в которой находится максимум погрешностей предсказаний, от обратного размера решетки $\frac{1}{L}$ в двойном логарифмическом масштабе. Анализ состоит в том, что если значения $\log(|T^{'} - T_c|)$ можно аппроксимировать прямой, то существует степенной рост корреляционной длины, и коэффициент наклона прямой означает значение критического показателя $\frac{1}{\nu}$.

Результаты показаны на рис. 11. Полученные графики подтверждают результаты предыдущего пункта 4.5 - степенной зависимости корреляционной длины не наблюдается.

При этом, как упоминалось ранее (п. 4.1-4.4), нейронная сеть определяет критическую температуру для фрустрированных состояний, хотя обучение происходило на выборке только с нефрустрированными конфигурациями. Эти результаты остаются верными, однако, обоснование таких предсказаний и поиск критического поведения требует дополнительных исследований.

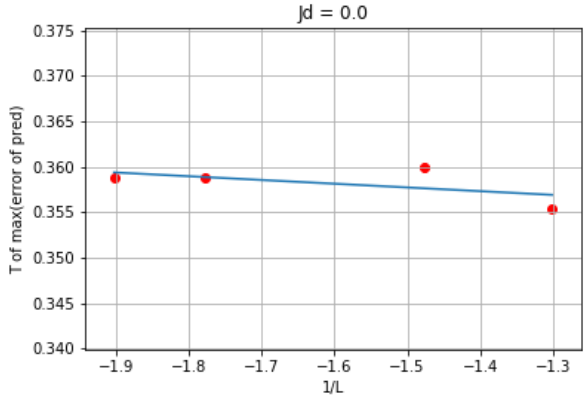

a)

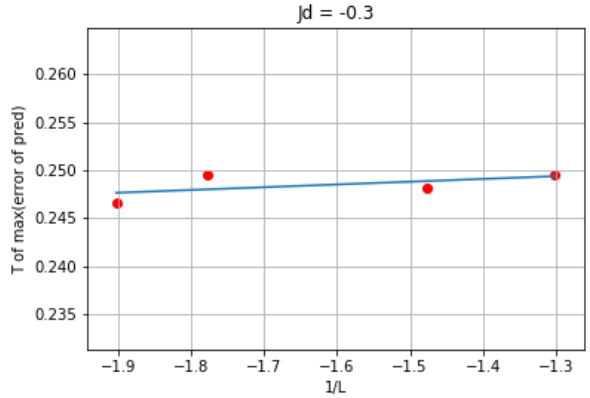

b)

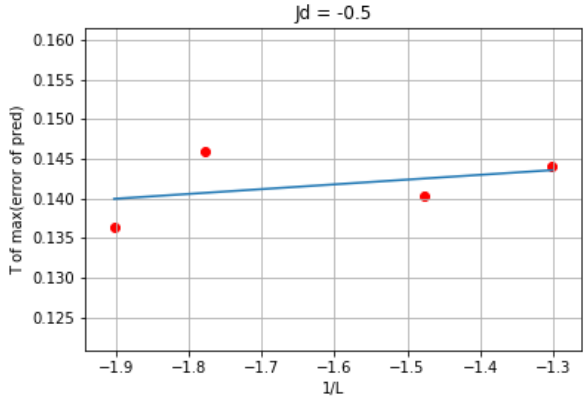

c)

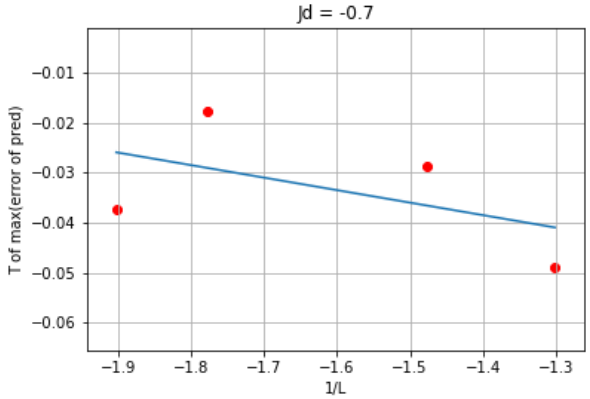

d)

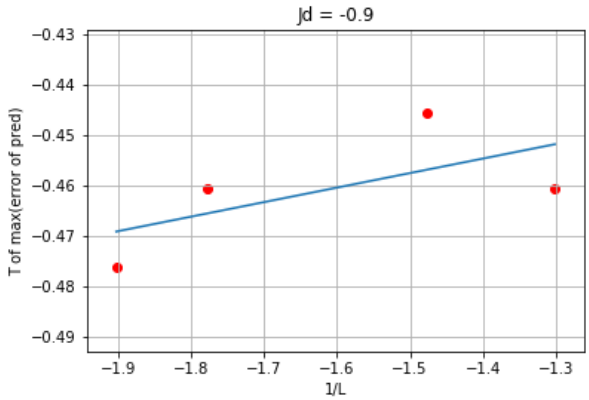

e)

Рис. 11: Поиск критического поведения на основе предсказаний нейронной сети для J_d = (a) 0.0, (b) -0.3, (c) -0.5, (d) -0.7, (e) -0.9.

5 Заключение

В данной работе мы исследовали модель Изинга с фрустрирующими взаимодействиями с помощью нейронных сетей. Были сгенерированны данные - конфигурации модели Изинга на квадратной и треугольной решетке. Затем была составлена архитектура нейронной сети, которая обучалась только на данных с нефрустрированными состояниями. После чего обученная нейронная сеть предсказывала, в каком из двух состояний - ферромагнитном или парамагнитном - находятся конфигурации как без, так и с фрустрирующими взаимодействиями. На основании полученных результатов мы отвечали на вопрос о том, получилось ли нейронной сети извлечь данные о физическом смысле модели Изинга: обнаруживается ли критическая температура для фрустрированных состояний и можно ли увидеть степенной рост корреляционной длины по полученным результатам.

Обнаружилось, что для выбранной архитектуры нейронная сеть в целом справляется с обнаружением критической температуры в том числе в случаях с фрустрирующими взаимодействиями, несмотря на то, что при обучении такие данные не поступали в нейронную сеть. Также предсказания становятся хуже с приближением критической температуры к нулю, и в полученных результатах существует зависимость от числа эпох обучения нейронной сети.

При этом, несмотря на то, что сеть "видит" новую критическую температуру, не удалось обнаружить степенного роста корреляционной длины, который характеризует фазовый переход в моделях Изинга. Вопрос о том, как нейронная сеть переносит знания о фазовом переходе на новые конфигурации, остается открытым и требует дополнительного изучения.

Ссылка на репозиторий с кодом, данными и полученными результатами находится по ссылке [13].

Список использованных источников

[1] J. Carrasquilla and R. G. Melko, "Machine learning phases of matter," *Nat. Phys.*, vol. **13**, pp. 431–434, May 2017.

[2] E. Ising, "Beitrag zur theorie des ferromagnetismus," *Z. Phys.*, vol. **31**, pp. 253–258, Feb. 1925.

[3] А.А.Билева, "Нейросетевой анализ фазовых переходов в классических моделях с геометрической фрустрацией. Анализ обобщающей способности и надежности предсказаний," 2021.

[4] L. Onsager, "Crystal statistics. i. a two-dimensional model with an order-disorder transition," *Phys. Rev.*, vol. **65**, pp. 117–149, Feb 1944.

[5] W. Janke, "Monte carlo methods in classical statistical physics," in *Computational Many-Particle Physics*, pp. 79–140, Berlin, Heidelberg: Springer Berlin Heidelberg, 2007.

[6] R. M. F. Houtappel, "Order-disorder in hexagonal lattices," *Physica*, vol. **16**, pp. 425–455, May 1950.

[7] W. Selke and L. N. Shchur, "Critical binder cumulant in a two-dimensional anisotropic ising model with competing interactions," *Phys. Rev. E*, vol. **80**, p. 042104, Oct 2009.

[8] A. Sokal, "Monte carlo methods in statistical mechanics: foundations and new algorithms," in *Functional integration*, pp. 131–192, Springer, 1997.

[9] V. Chertenkov and L. Shchur, "Universality classes and machine learning," in *Journal of Physics: Conference Series*, vol. **1740**, p. 012003, IOP Publishing, 2021.

[10] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016. `http://www.deeplearningbook.org`.

[11] BCEWithLogitsLoss. `https://pytorch.org/docs/stable/generated/torch.nn.BCEWithLogitsLoss.html`.

[12] D. Kingma and J. Ba, "Adam: A method for stochastic optimization," *International Conference on Learning Representations*, 2014.

[13] Репозиторий с данными и кодом реализации: https://github.com/diana-sukhoverkhova/diploma-Ising-nn.

Приложения

Приложение 1. Графики усредненных функции потерь, предсказаний и погрешностей предсказаний для 20 температур

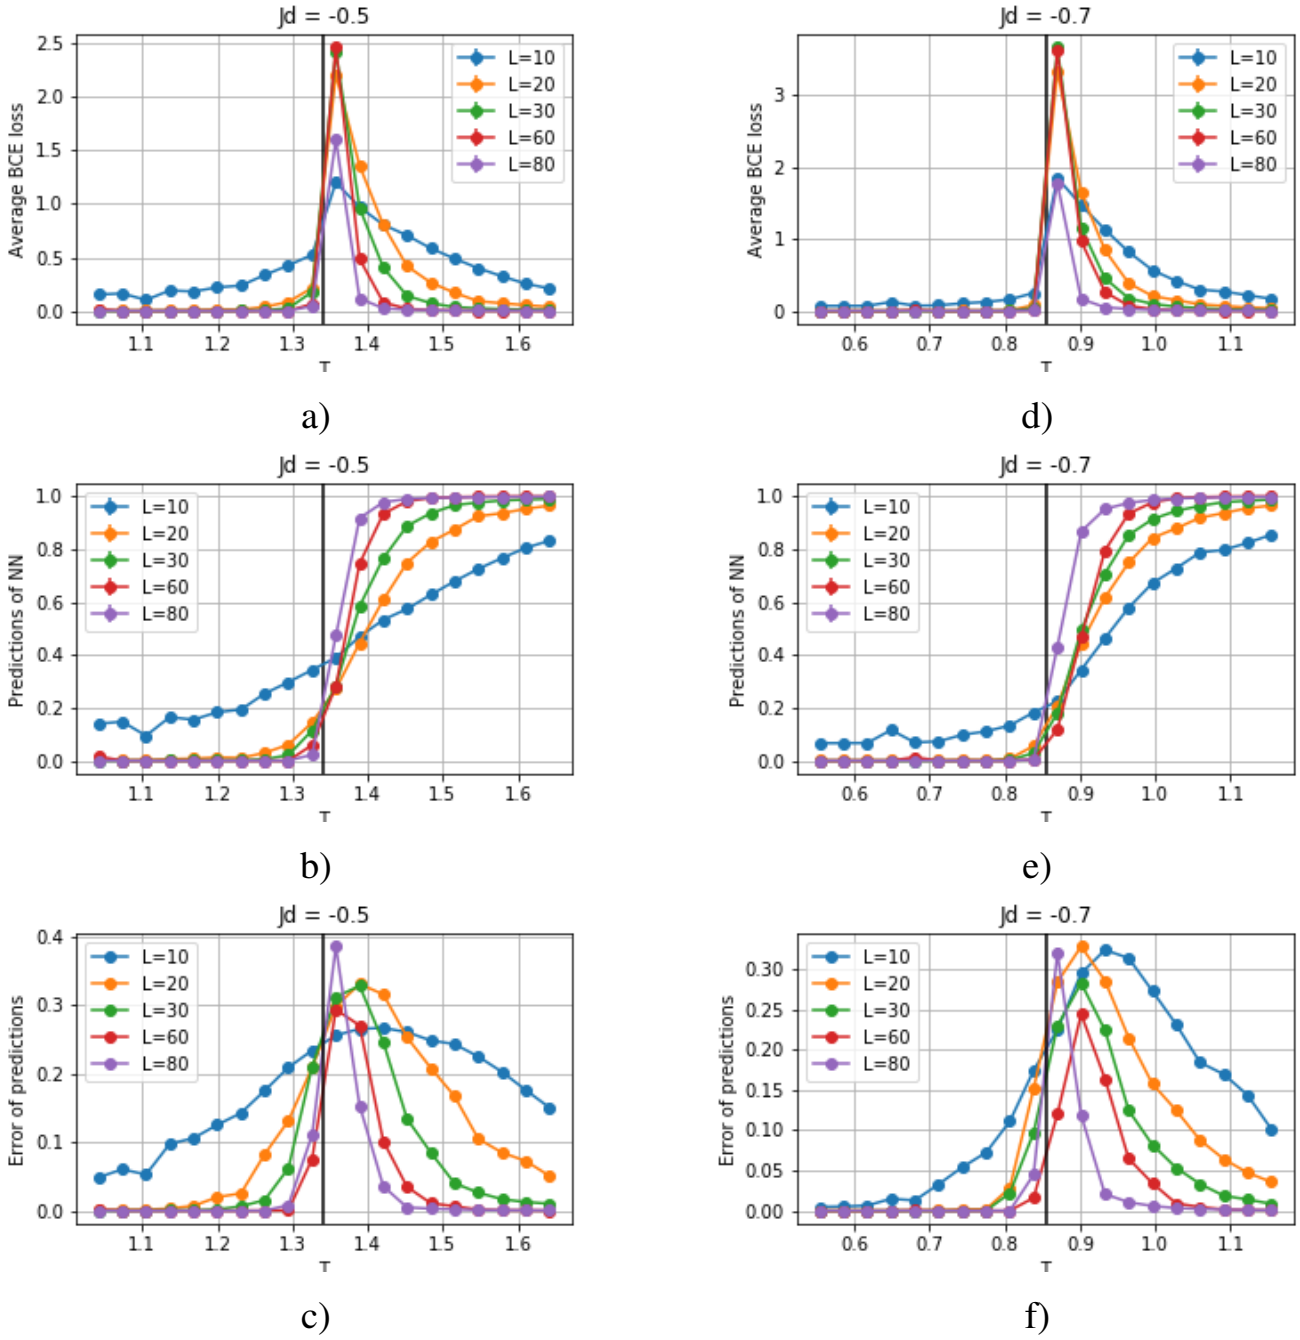

Рис. 12: Усредненные функция потерь (a, d) ((4.1)), предсказания (b, e) ((4.2)) и погрешности предсказаний (c, f) ((4.3)) сети для $J_d = -0.5$ и $J_d = -0.7$ в диапазоне $T_c \pm 0.3$ для 20 значений температур; вертикальной линией обозначена критическая температура, уравнение (1.4).

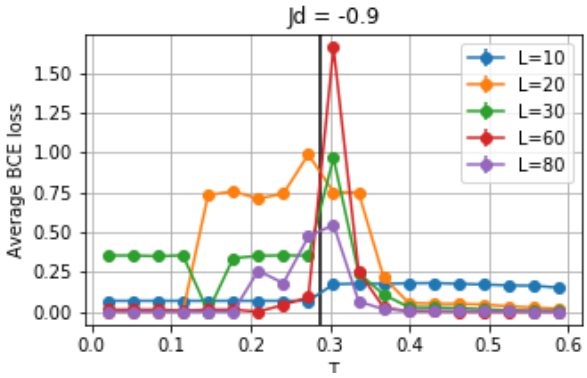

a)

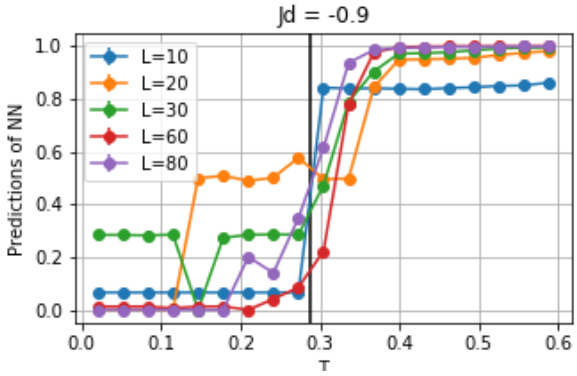

b)

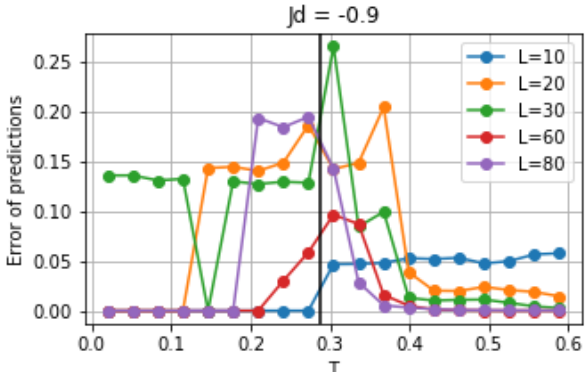

c)

Рис. 13: Усредненные функция потерь (a) ((4.1)), предсказания (b) ((4.2)) и погрешности предсказаний (c) ((4.3)) сети для $J_d = -0.9$ в диапазоне $T_c \pm 0.3$ для 20 значений температур; вертикальной линией обозначена критическая температура, уравнение (1.4).

Приложение 2. Графики усредненных функции потерь, предсказаний и погрешностей предсказаний для 100 температур

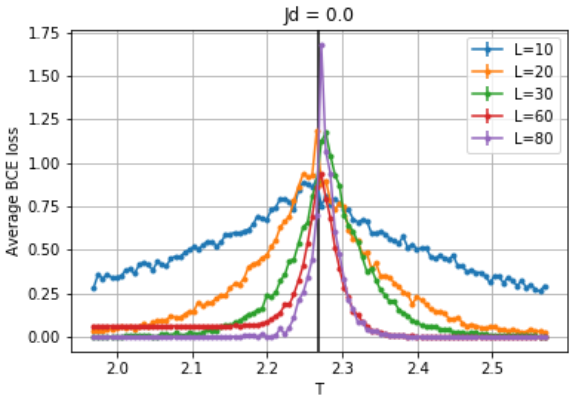

a)

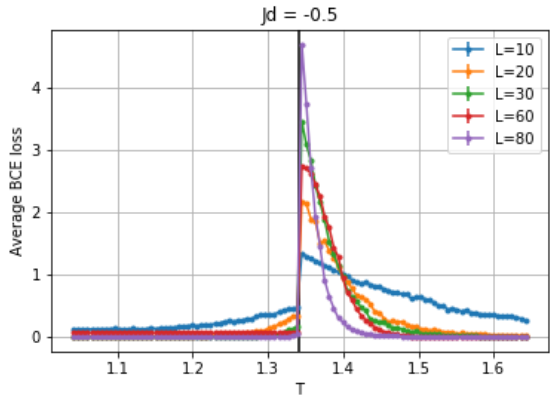

d)

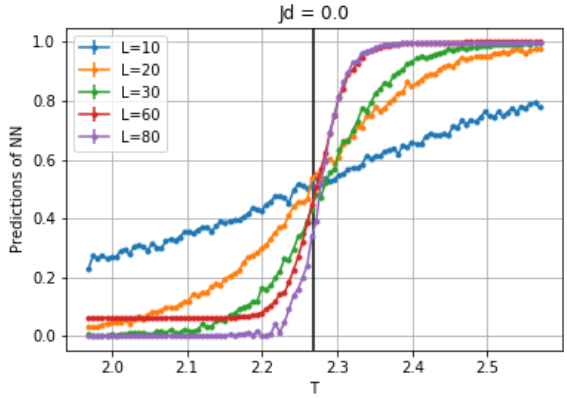

b)

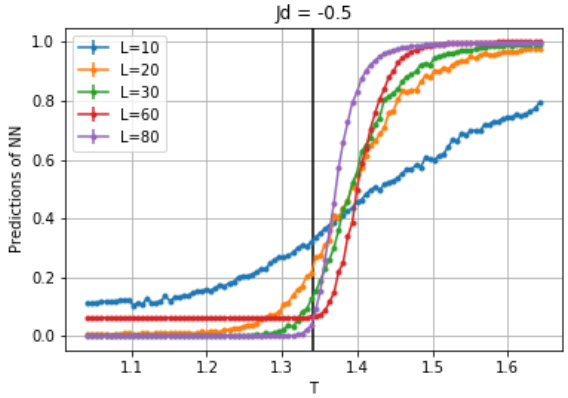

e)

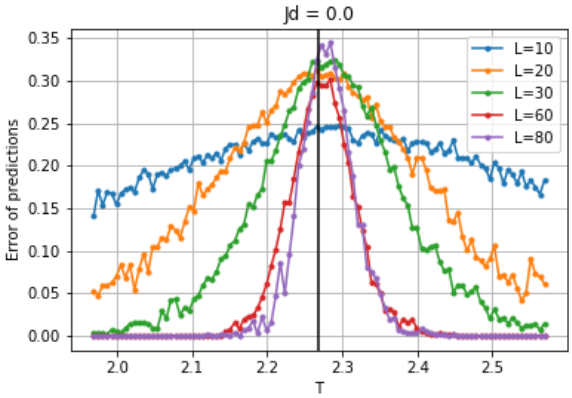

c)

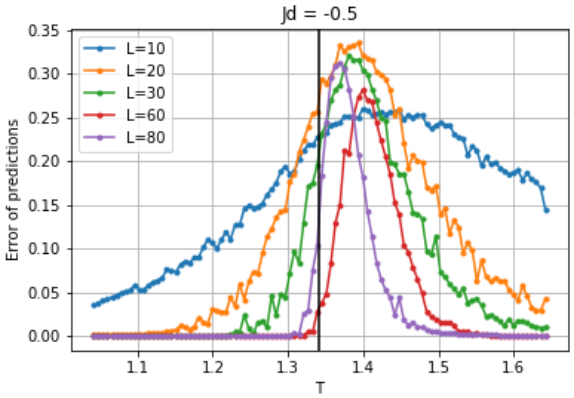

f)

Рис. 14: Усредненные функция потерь (a, d) (4.1), предсказания (b, e) (4.2) и погрешности предсказаний (c, f) (4.3) сети для $J_d = 0.0$ и $J_d = -0.5$ в диапазоне $T_c \pm 0.3$ для 100 значений температур; вертикальной линией обозначена критическая температура, уравнение (1.4).

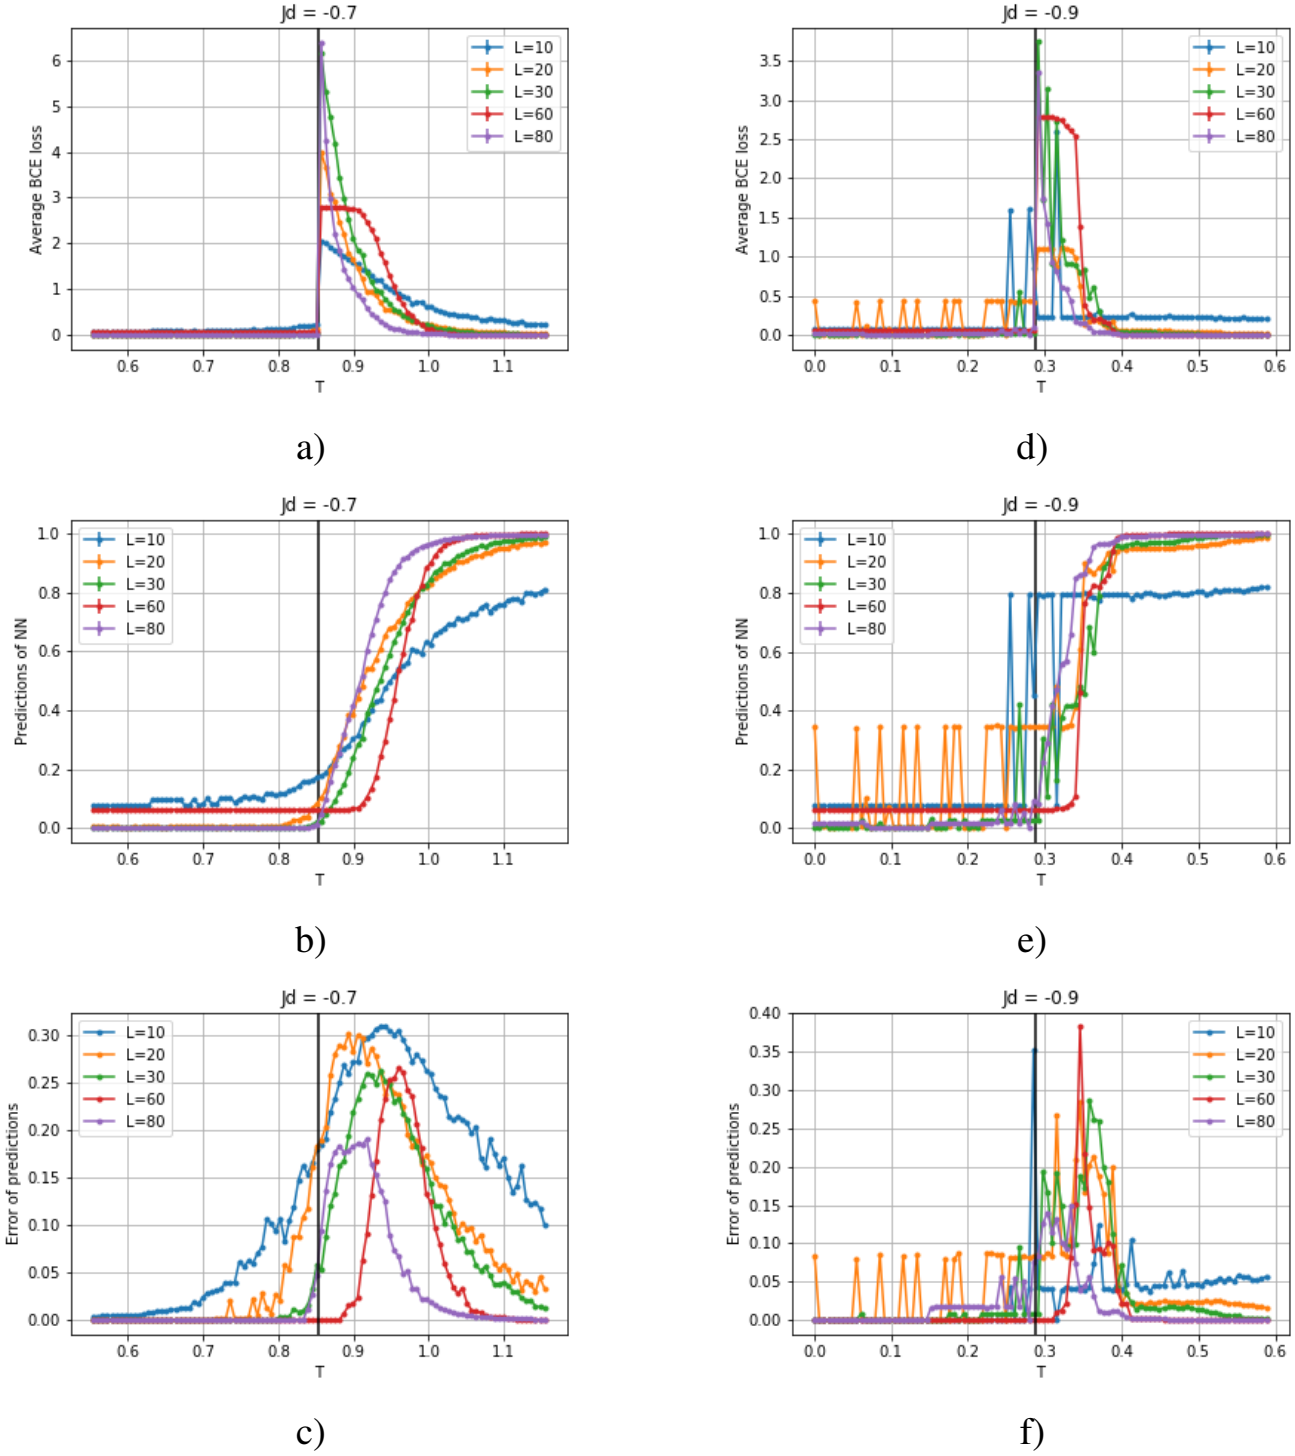

Рис. 15: Усредненные функция потерь (a, d) (4.1), предсказания (b, e) (4.2) и погрешности предсказаний (c, f) (4.3) сети для $J_d = -0.7$ и $J_d = -0.9$ в диапазоне $T_c \pm 0.3$ для 100 значений температур; вертикальной линией обозначена критическая температура, уравнение (1.4).

Приложение 3. Результаты при обучении сети в течение 2 эпох

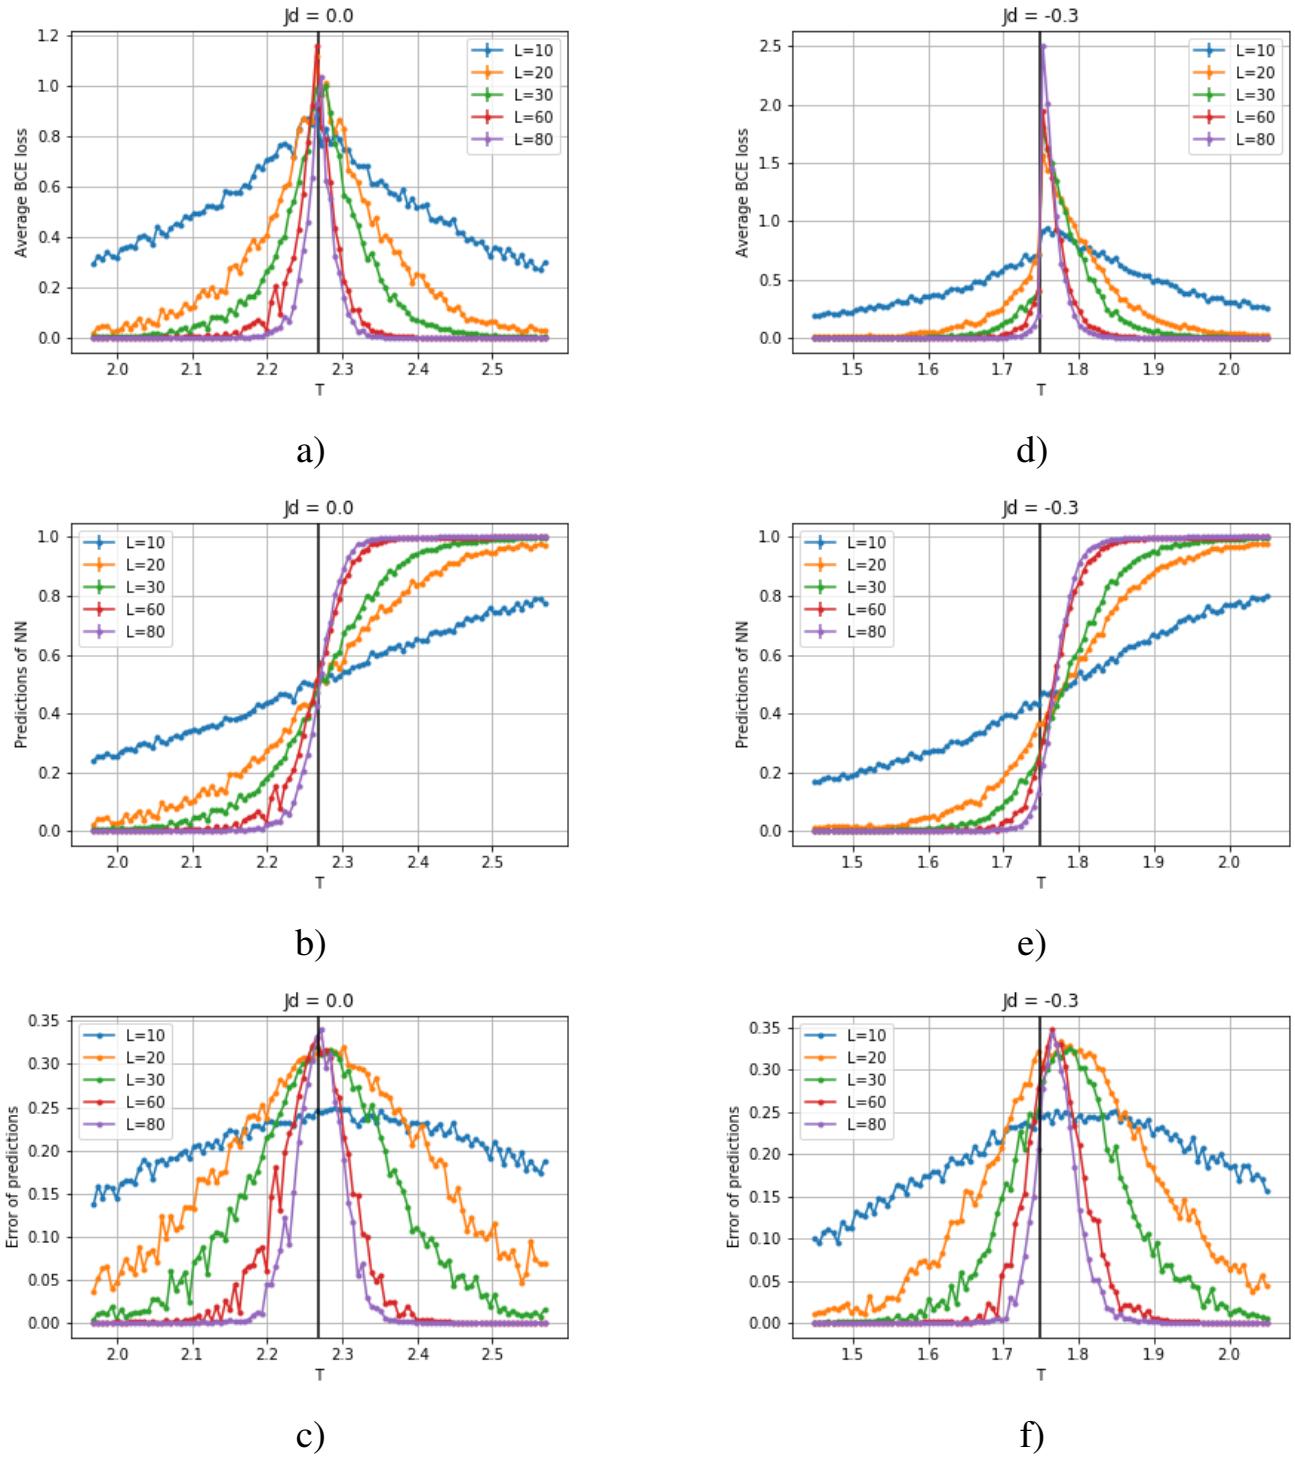

Рис. 16: Усредненные функция потерь (a, d) (4.1), предсказания (b, e) (4.2) и погрешности предсказаний (c, f) (4.3) сети, обученной в течение 2 эпох, для $J_d = 0.0$ и $J_d = -0.3$ в диапазоне $T_c \pm 0.3$ для 100 значений температур; вертикальной линией обозначена критическая температура, уравнение (1.4).

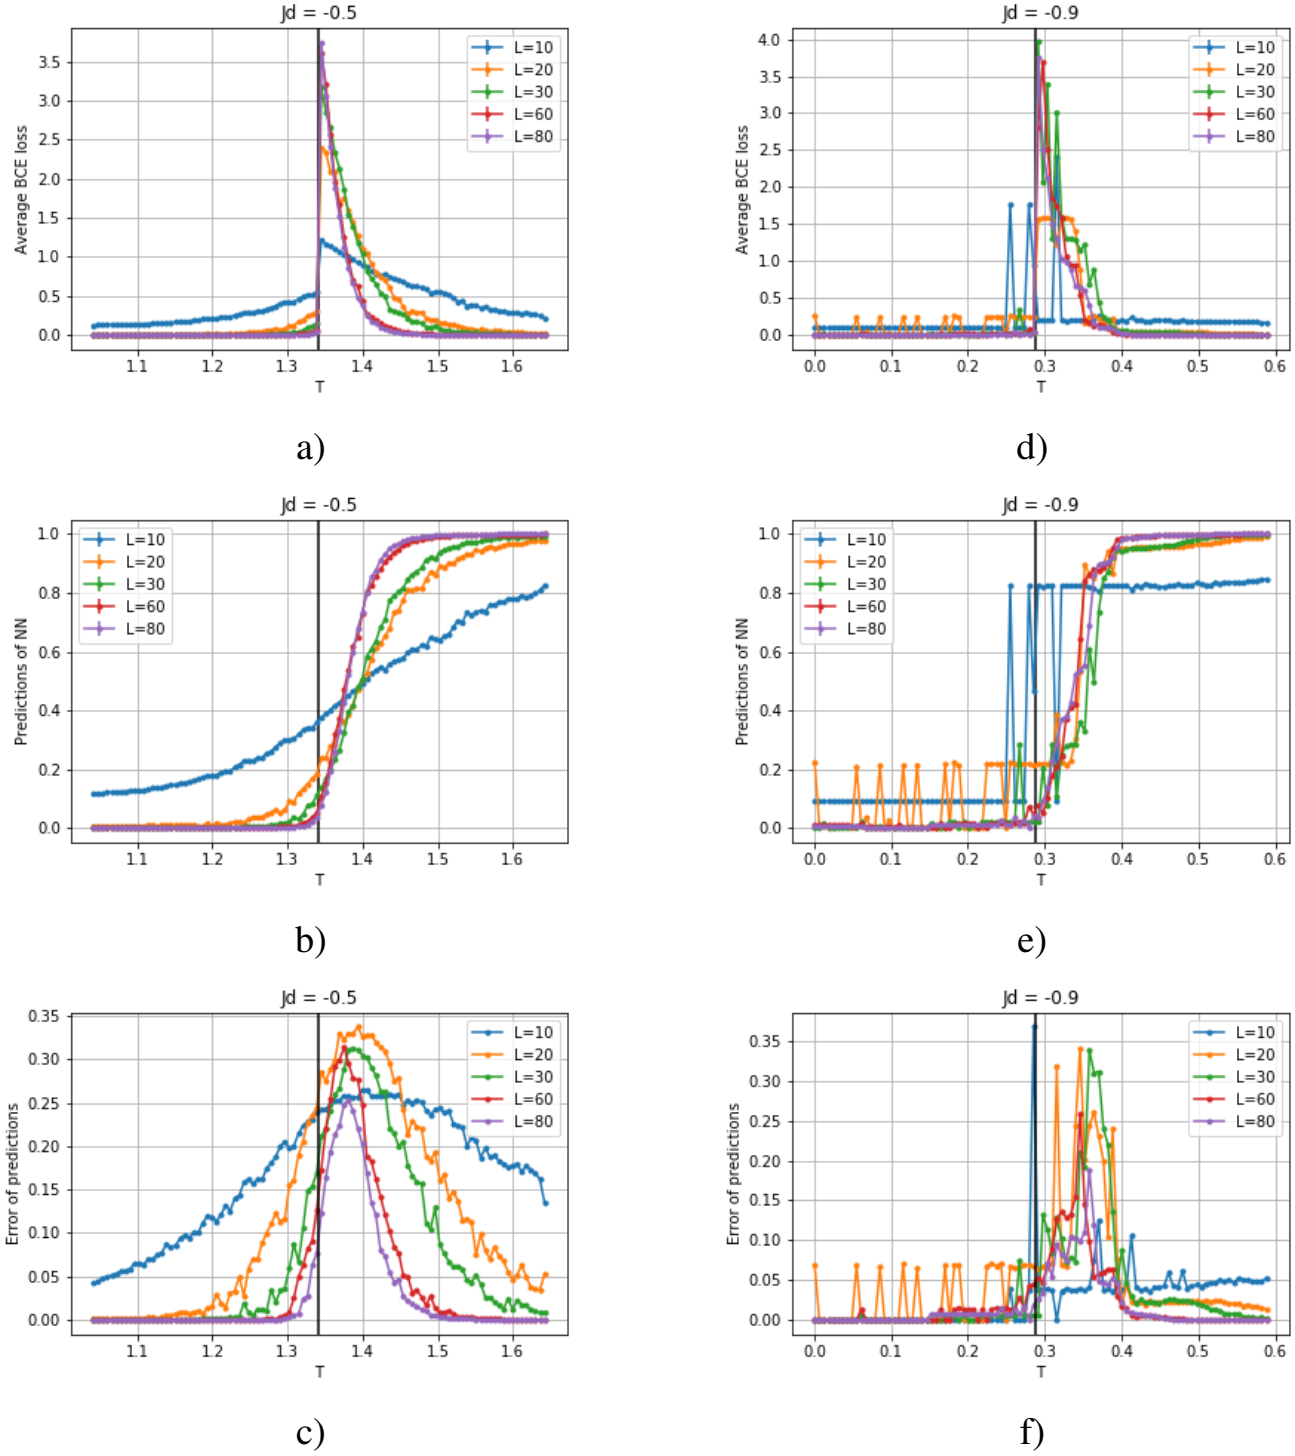

Рис. 17: Усредненные функция потерь (a, d) (4.1), предсказания (b, e) (4.2) и погрешности предсказаний (c, f) (4.3) сети, обученной в течение 2 эпох, для $J_d = -0.5$ и $J_d = -0.9$ в диапазоне $T_c \pm 0.3$ для 100 значений температур; вертикальной линией обозначена критическая температура, уравнение (1.4).

Приложение 4. Результаты при обучении в интервале $[0.03, 3.5]$

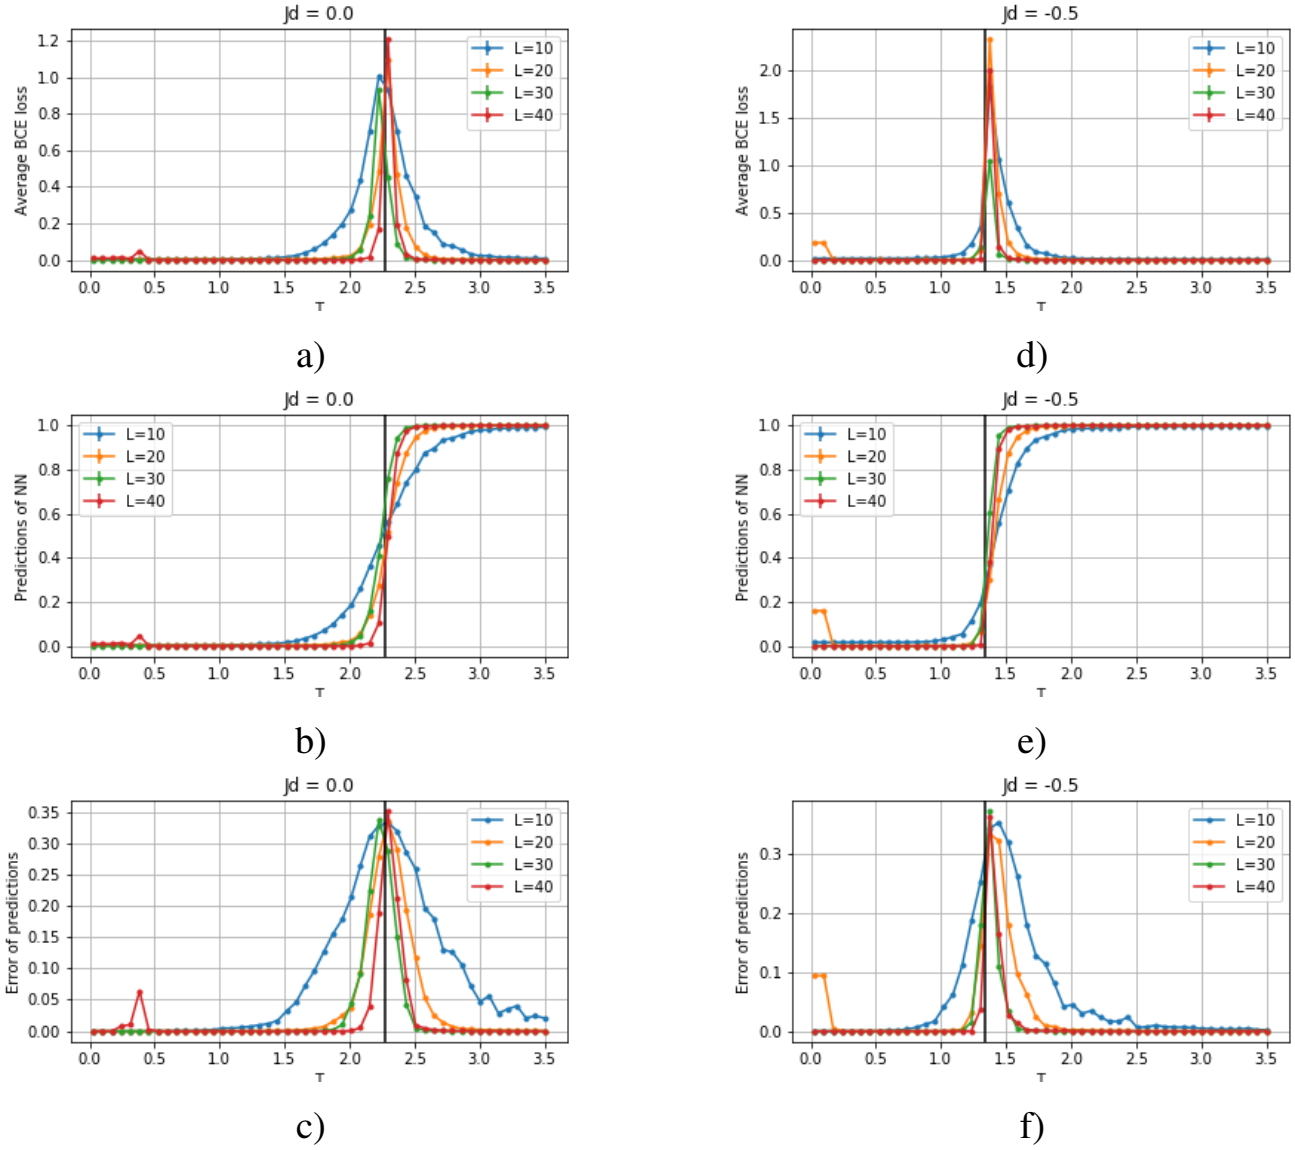

Рис. 18: Усредненные функция потерь (a, d) (4.1), предсказания (b, e) (4.2) и погрешности предсказаний (c, f) (4.3) сети для $J_d = 0.0$ и $J_d = -0.5$ в диапазоне $[0.03, 3.5]$ для 50 значений температуры; вертикальной линией обозначена критическая температура, уравнение (1.4).

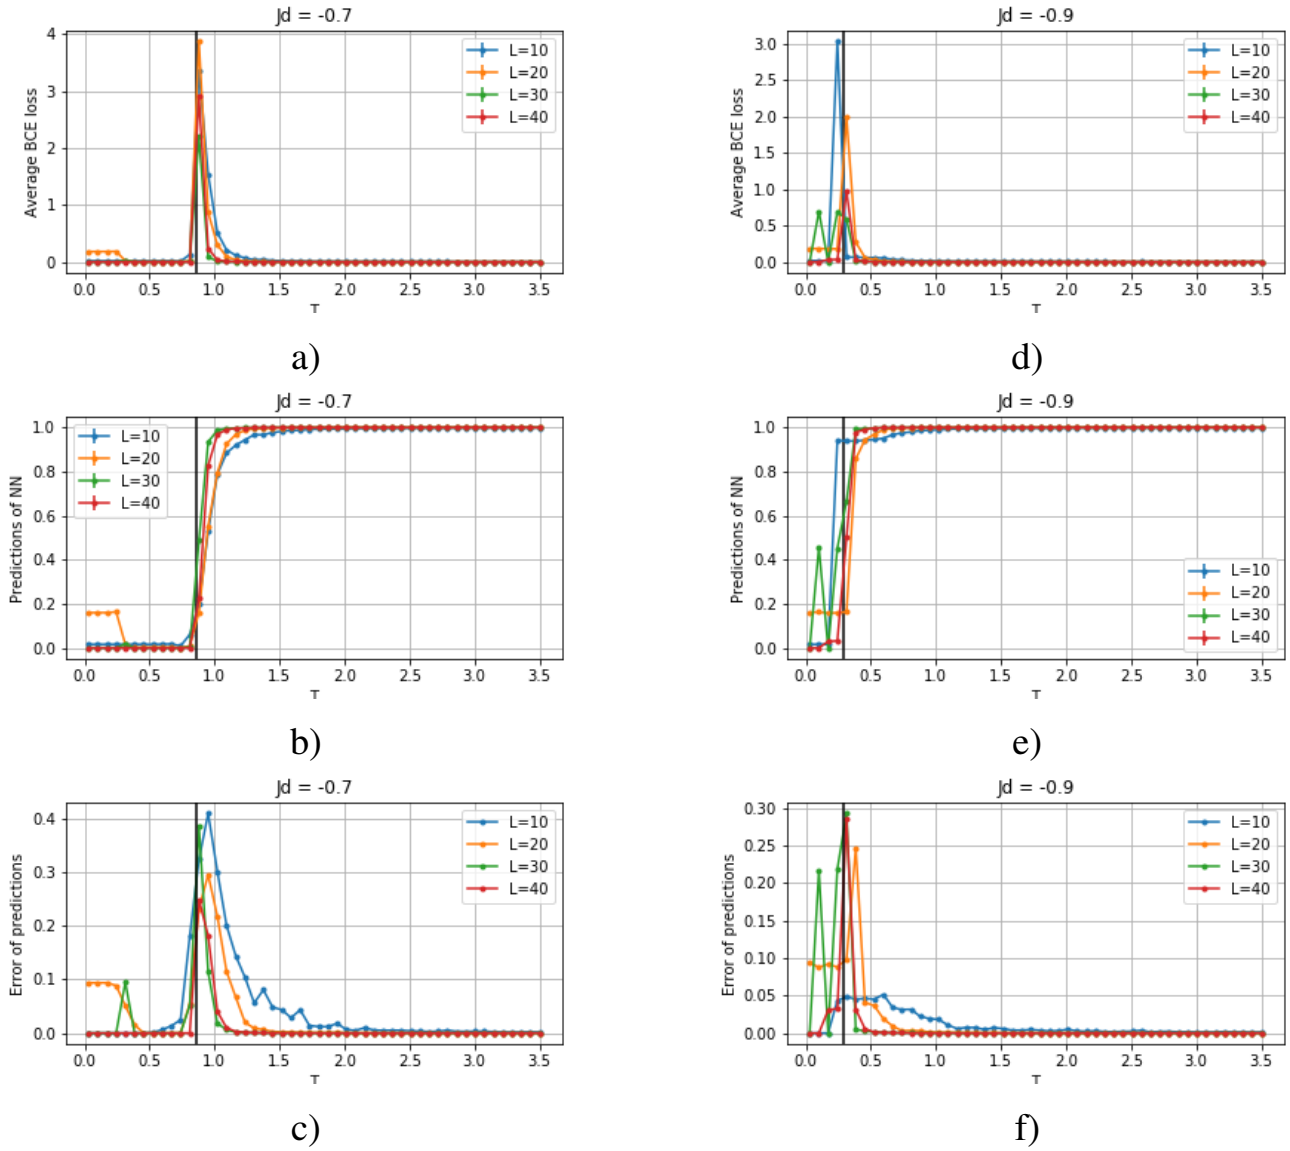

Рис. 19: Усредненные функция потерь (a, d) (4.1), предсказания (b, e) (4.2) и погрешности предсказаний (c, f) (4.3) сети для $J_d = -0.7$ и $J_d = -0.9$ в диапазоне $[0.03, 3.5]$ для 50 значений температур; вертикальной линией обозначена критическая температура, уравнение (1.4).

Приложение 5. Анализ усредненной функции потерь

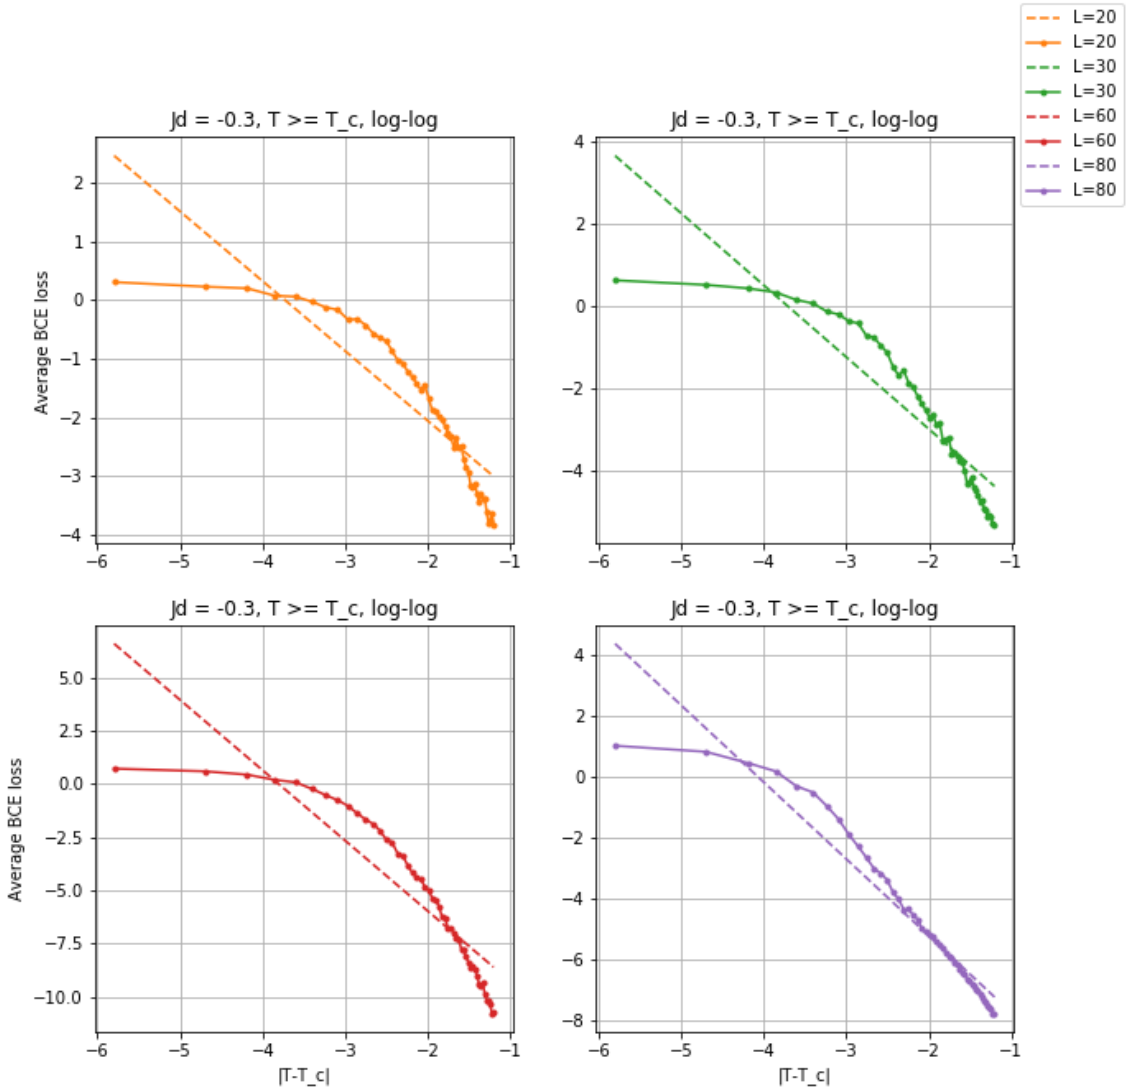

Рис. 20: Усредненная функция потерь (4.1) при температурах выше критической, в двойном логарифмическом масштабе, $J_d = -0.3$.

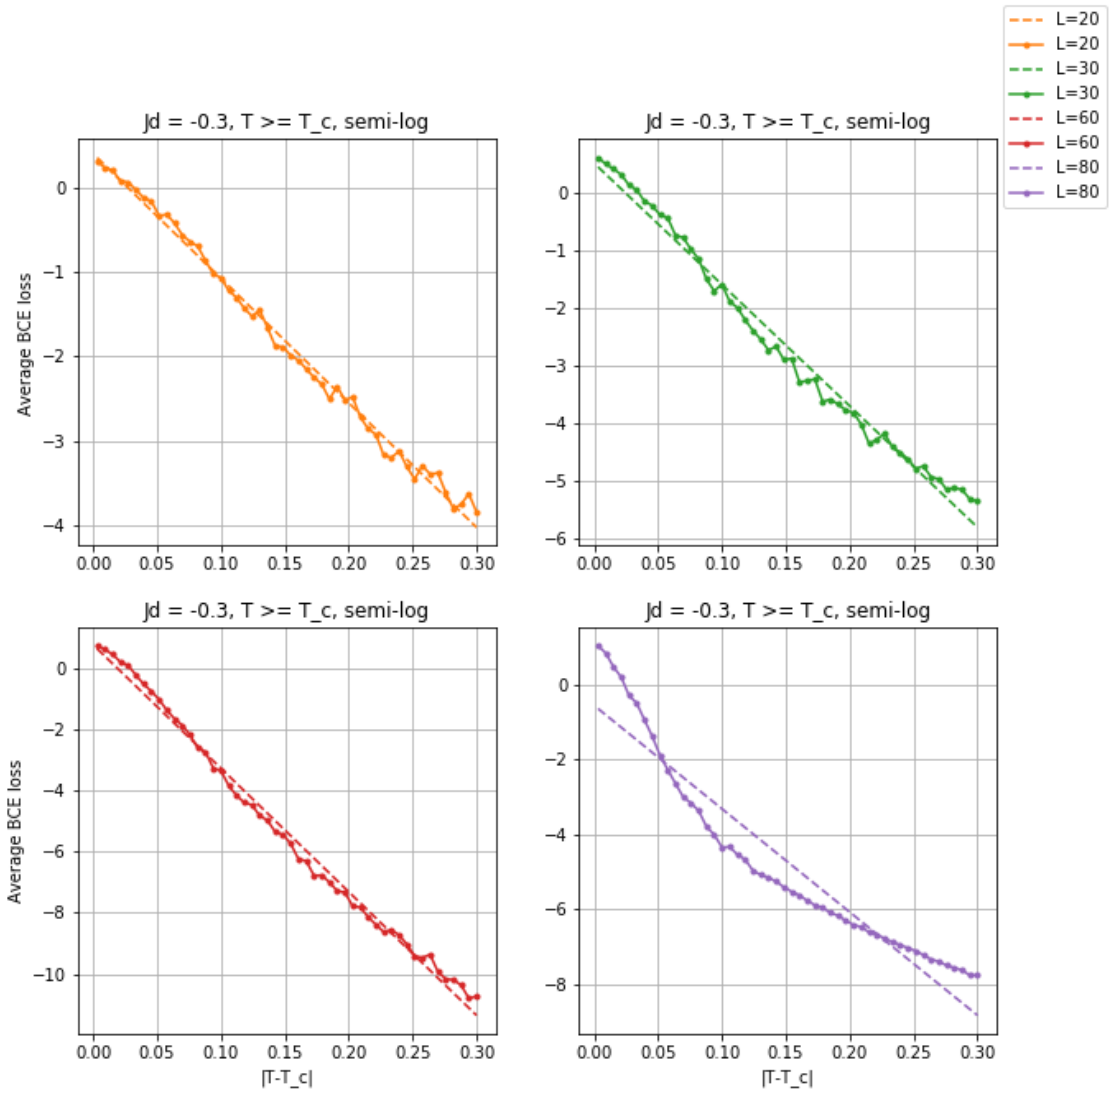

Рис. 21: Усредненная функция потерь (4.1) при температурах выше критической, в полулогарифмическом масштабе, $J_d = -0.3$.